

# AAAR：AI 加速学术研究的方法论与经验

Zhang Yu

2026-01-20

# Table of contents

<b>Welcome</b>	<b>6</b>
Buy Today!	6
快速导览	6
重点提示	6
关键原则（有序列表）	6
工具与流程（无序列表）	6
表格示例	6
图片示例	7
代码块示例	7
引用与引用框	8
超链接与行内代码	8
公式示例	8
任务列表	8
注脚与脚注引用	8
引用文献与参考文献	8
折叠块	9
分隔线	9
公式编号与引用	9
图注与交叉引用	9
代码与数据	9
<b>1 序章   为什么写这本书</b>	<b>11</b>
1.1 一、从一次失败的文献综述说起	11
1.2 二、为什么现有的“AI 科研指南”让我不满意	11
1.3 三、这本书想要提供什么	12
1.3.1 3.1 一个可持续的思维框架	12
1.3.2 3.2 一套可复现的工作流	12
1.3.3 3.3 必要的批判性	12
1.4 四、这本书写给谁	13
1.4.1 4.1 不同阶段的读者	13
1.4.2 4.2 不同学科的读者	13
1.4.3 4.3 不同技术背景的读者	13
1.5 五、这本书不是什么	13
1.6 六、本书的结构与阅读建议	14
1.6.1 6.1 整体结构	14
1.6.2 6.2 阅读路径建议	14
1.6.3 6.3 每章的结构	14
1.7 七、一些重要的声明	15
1.7.1 7.1 关于时效性	15
1.7.2 7.2 关于局限性	15
1.7.3 7.3 关于 AI 辅助写作	15
1.7.4 7.4 关于争议性观点	15
1.8 八、为什么选择开源	16
1.8.1 8.1 可复现与可验证	16
1.8.2 8.2 持续更新	16
1.8.3 8.3 社区协作	16
1.8.4 8.4 价值观的表达	16

1.9	九、我们正处于什么样的时刻	16
1.9.1	9.1 炒作周期的高峰与低谷	16
1.9.2	9.2 学术界的特殊处境	17
1.9.3	9.3 一场正在发生的范式转移	17
1.9.4	9.4 个人选择的重要性	17
1.10	十、致谢	17
1.11	十一、写在最后	18
<b>2</b>	<b>第 1 章 AI 能做什么，不能做什么</b>	<b>19</b>
<b>3</b>	<b>第 2 章 幻觉、偏差、泄露：三类核心风险</b>	<b>20</b>
<b>4</b>	<b>第 3 章 提示词不是方法论</b>	<b>21</b>
4.1	一、一场关于提示词的迷信	21
4.2	二、提示词能做什么，不能做什么	21
4.2.1	2.1 提示词确实有用	21
4.2.2	2.2 提示词不能做什么	21
4.2.3	2.3 核心区分：流程辅助 vs. 判断替代	22
4.3	三、为什么提示词被过度神化	22
4.3.1	3.1 简单问题的诱惑	22
4.3.2	3.2 商业利益的驱动	22
4.3.3	3.3 对 AI 能力的误解	23
4.3.4	3.4 可观察性偏差	23
4.4	四、从“提问技巧”走向“研究系统”	23
4.4.1	4.1 什么是“研究系统”	23
4.4.2	4.2 系统的核心特征	24
4.4.3	4.3 AI 在系统中的位置	24
4.5	五、建立自己的工作流原则	24
4.5.1	5.1 任务拆解原则	24
4.5.2	5.2 层级输出原则	25
4.5.3	5.3 验证机制原则	25
4.5.4	5.4 版本记录原则	25
4.5.5	5.5 边界意识原则	26
4.6	六、一个完整的例子	26
4.6.1	6.1 没有系统的做法	26
4.6.2	6.2 有系统的做法	26
4.6.3	6.3 两种做法的对比	27
4.7	七、写在最后	27
<b>5</b>	<b>第 4 章 信息压缩与文献整理</b>	<b>29</b>
5.1	引言：从信息过载到结构化理解	29
5.2	一、文献筛选与主题聚类	29
5.2.1	1.1 文献筛选的两阶段模型	29
5.2.2	1.2 设计有效的筛选指令	29
5.2.3	1.3 主题聚类的策略	30
5.2.4	1.4 一个实践案例	30
5.3	二、长上下文模型的正确用法	31
5.3.1	2.1 长上下文能力的本质与局限	31
5.3.2	2.2 分层处理策略	31
5.3.3	2.3 输入质量的重要性	31
5.3.4	2.4 输出设计与质量控制	31
5.3.5	2.5 一个错误使用的案例	32
5.4	三、可信综述生成：引用与验证	32
5.4.1	3.1 为什么综述生成是高风险任务	32
5.4.2	3.2 AI 在综述生成中的适当角色	32

5.4.3	3.3  引用验证的系统方法	33
5.4.4	3.4  建立可追溯的证据链	33
5.4.5	3.5  AI 辅助综述的披露与伦理	33
5.5	四、从工具到能力：信息素养的新维度	33
5.5.1	4.1  信息压缩作为研究者的核心能力	33
5.5.2	4.2  人机协作的最优配置	34
5.5.3	4.3  未来研究者的信息素养	34
5.6	结语	34
6	第 5 章 结构化表达与写作	35
7	第 6 章 代码与计算能力	36
8	第 7 章 知识管理与协作	37
9	第 8 章 选题与研究问题	38
10	第 9 章 文献与理论构建	39
11	第 10 章 数据获取与构造	40
12	第 11 章 数据清洗与分析	41
13	第 12 章 写作、投稿与传播	42
14	第 13 章 RA Level：工具层	43
15	第 14 章 Supervisor Level：认知协作层	44
16	第 15 章 Domain Expert Level：推理与建模层	45
17	第 16 章 Agent Level：AI 作为行动者	46
17.1	引言：当 AI 不再只是工具	46
17.2	一、AI 进入社会科学的本体论	46
17.2.1	1.1  社会科学的基本预设	46
17.2.2	1.2  三种本体论立场	46
17.2.3	1.3  对社会科学方法的影响	47
17.3	二、模拟社会与虚拟样本	47
17.3.1	2.1  AI 驱动的社会模拟	47
17.3.2	2.2  虚拟样本的方法论问题	47
17.3.3	2.3  模拟的认识论地位	48
17.3.4	2.4  负责任的模拟研究	48
17.4	三、“行动者”概念的扩展	48
17.4.1	3.1  从人类行动者到异质行动者	48
17.4.2	3.2  行动能力的分解	48
17.4.3	3.3  人机混合行动者	49
17.4.4	3.4  对社会理论的启示	49
17.5	四、研究者的立场与策略	49
17.5.1	4.1  明确研究对象	49
17.5.2	4.2  保持方法论自觉	50
17.5.3	4.3  伦理考量	50
17.5.4	4.4  跨学科对话	50
17.6	结语：在工具与行动者之间	50
18	第 17 章 Governance Level：制度与治理层	52

19 终章   AI 时代研究者的新能力结构	53
20 附录（可选）	54

# Welcome

这是一个用于展示排版和视觉效果封面页。我在这里补充了多种 Markdown 元素，方便你快速判断整体的排版质感与细节风格。

## Buy Today!

AAAR: AI 加速学术研究的方法论与经验

Open access • Print version coming soon.

Buy from Amazon Buy from Publisher Download PDF

## 快速导览

本书面向从本科生到教授的读者。你可以按“能力模块”阅读，也可以按“科研工作流”顺序阅读。

## 重点提示

AI 擅长生成，但不擅长负责。使用 AI 的关键在于验证与责任分配。

## 关键原则（有序列表）

1. 先定义问题，再让 AI 参与。
2. 先验证证据，再相信输出。
3. 先记录流程，再扩展规模。

## 工具与流程（无序列表）

- 文献：综述不是堆摘要，而是证据链。
- 数据：清洗的透明性决定可信度。
- 写作：表达是结果，逻辑是核心。

## 表格示例

模块	典型任务	主要风险
信息压缩	文献综述	幻觉引用
数据处理	清洗/结构化	规则不透明
写作表达	初稿/润色	逻辑空洞

## 图片示例



Figure 1: 封面示例

## 代码块示例

你是我的研究助理。请将下面的研究问题拆解成可检验的子问题，并给出潜在的数据来源与方法路径。输出为列表。

## 引用与引用框

“AI 擅长生成，但不擅长负责。”  
——写作时请把证据链放在第一位。

### 提示

把 AI 当作“加速器”，不要当作“裁判”。

### 警告

不要把未发表的数据或敏感信息直接交给模型。

## 超链接与行内代码

- 官网链接：<https://yuzhangsjtu.github.io/AAAR/>
- 仓库链接：<https://github.com/yuzhangsjtu/AAAR>
- 行内代码示例：使用 `quarto render` 重新生成站点

## 公式示例

这是一条行内公式： $E[X] = \sum_i x_i p_i$ ，以及一个块级公式：

$$\hat{\tau} = \frac{1}{N} \sum_{i=1}^N (Y_i^1 - Y_i^0)$$

## 任务列表

- ☒ 完成大纲
- ☒ 生成示例页面
- ☐ 补充案例
- ☐ 进一步润色正文

## 注脚与脚注引用

这是一个脚注示例。<sup>1</sup>

## 引用文献与参考文献

这是一条文献引用示例 (Knuth 1984)，引用会自动生成参考文献列表。

---

<sup>1</sup>这是脚注内容，用于测试排版与字号。



## 折叠块

### 💡 折叠内容

这里是折叠块的内容，用来展示 Anthropic 风格下的折叠区域样式。

## 分隔线

---

## 公式编号与引用

带编号的公式如下：

$$\tau = E[Y(1) - Y(0)] \quad (0.1)$$

在正文中引用该公式：见公式 Equation 0.1。

## 图注与交叉引用

在正文中引用该图：见图 Figure 2。

## 代码与数据

本书所有内容均开源：

- 代码仓库：<https://github.com/yuzhangsjtu/AAAR>
- 在线阅读：<https://yuzhangsjtu.github.io/AAAR/>



Figure 2: 示意图：AI 加速研究的简单流程

# 1 序章 | 为什么写这本书

## 1.1 一、从一次失败的文献综述说起

2023 年初的某个深夜，我坐在办公室里盯着屏幕，面前是一份用 ChatGPT 生成的文献综述初稿。那时候，GPT-4 刚刚发布不久，整个学术圈都在讨论“AI 会不会取代研究者”。我也不能免俗，决定亲自试一试。

那篇综述的主题是关于社会网络对信息传播的影响——一个我研究了好几年的领域。我给模型提供了详细的背景、明确的问题、甚至列出了几篇我认为重要的文献，然后让它“帮我写一篇文献综述”。

结果出乎意料地“好”。结构清晰，语言流畅，甚至引用格式都很规范。如果只看表面，这完全可以当作一份合格的课程作业。但当我开始逐条核对引用时，问题出现了：十二条引用中，有四条是完全捏造的——作者名对不上，期刊名不存在，DOI 链接指向 404。更糟糕的是，另外三条虽然文献确实存在，但模型对它们的概括与原文观点完全相反。

那一刻我意识到，这不仅仅是“工具有 bug”的问题。模型并没有“理解”什么是文献综述，它只是在模仿文献综述的形式——用流畅的语言把看起来相关的东西串起来。它不知道证据链是什么，不知道学术引用的意义在于可追溯和可验证，更不知道一条错误的引用可能导致整个论证链条的崩塌。

这次经历让我开始思考一个更深层的问题：AI 究竟能在学术研究中扮演什么角色？它显然可以提高效率，但效率的提高如果建立在可靠性的下降之上，那这种“加速”的代价是什么？

## 1.2 二、为什么现有的“AI 科研指南”让我不满意

在那次失败之后，我开始系统地阅读市面上关于“如何在学术研究中使用 AI”的书籍、文章和教程。令我失望的是，绝大多数内容都存在以下几个问题。

**第一，工具堆砌，缺乏方法论。**很多指南的逻辑是：这里有一个 AI 工具，它能做 X，所以你应该用它做 X。这种“功能清单”式的写作完全忽略了一个核心问题——为什么你需要做 X？X 在你的研究流程中扮演什么角色？用 AI 做 X 和用传统方法做 X 有什么本质区别？没有方法论的工具介绍，最多只能培养“熟练的操作员”，而不是“有判断力的研究者”。

**第二，回避风险，夸大效用。**或许是出于推广的目的，很多内容只讲 AI 能做什么，不讲它不能做什么；只讲成功案例，不讲失败教训。幻觉（hallucination）被轻描淡写地提一句，然后就被“所以记得核实”这种空洞的建议带过。但问题是，核实需要成本，而且很多时候你根本不知道哪些地方需要核实。如果一个工具需要你“处处核实”才能安全使用，那它到底是帮你节省时间，还是把风险转嫁给你？

**第三，混淆“更快”与“更好”。**我见过太多这样的句式：“以前需要三天的工作，现在只需要三小时。”这种表述隐含了一个危险的假设——原来三天的工作和现在三小时的工作是等价的。但真的等价吗？三天的文献阅读和三小时的模型总结，产出的是同样的理解吗？三天的数据清洗和三小时的自动化处理，留下的是同样的审计痕迹吗？效率的提升往往伴随着某些东西的损失，但这些损失很少被讨论。

**第四，对“责任”的回避。**当 AI 参与学术生产，责任如何分配？如果模型生成的内容包含错误，责任在使用者还是开发者？如果审稿人无法分辨 AI 生成的文本，学术诚信的边界在哪里？这些问题极少被正面回应。很多指南的态度是“工具是中性的，看你怎么用”——这当然是正确的废话，但它回避了真正的难题：在实践中，我们如何具体地、可操作地分配责任？

**第五，缺乏批判性反思。**AI 的广泛使用可能对学术生态产生什么长期影响？如果所有人都用同样的模型来“加速”研究，学术多样性会不会下降？如果 AI 让写作变得更容易，会不会有更多的论文但更少的发现？如果模型的训练数据主要来自英文文献，非英语学术传统会不会被进一步边缘化？这些问题几乎没有人讨论。

正是这些不满意，推动我写这本书。我想提供一种不同的视角——不是“AI 能帮你做什么”，而是“你应该如何与 AI 协作，同时保持研究的严谨性”。

## 1.3 三、这本书想要提供什么

基于上述反思，我给这本书设定了三个核心目标。

### 1.3.1 3.1 一个可持续的思维框架

第一个目标是提供一个可持续的思维框架。所谓“可持续”，是指这个框架不会因为某个具体工具的更新而过时。GPT-5 出来了，这个框架依然适用；换一个模型，框架依然成立。

这个框架的核心是三个问题：

1. **AI 在这个任务中的能力边界在哪里？**它擅长什么？不擅长什么？会犯什么类型的错误？
2. **这个任务的质量标准是什么？**我们用什么指标判断任务完成得好不好？这些指标中哪些是 AI 容易满足的，哪些是困难的？
3. **人机协作的最优分工是什么？**哪些环节交给 AI 更高效？哪些环节必须由人类来做？交接点在哪里？如何确保交接不丢失关键信息？

这三个问题不是一次性回答的，而是在每一个具体任务中反复追问的。我希望读者在读完这本书之后，能够在面对任何新工具、新场景时，自动地问出这三个问题，并且有能力给出自己的回答。

### 1.3.2 3.2 一套可复现的工作流

第二个目标是提供一套可复现的工作流。“可复现”是学术研究的基石之一，但在 AI 辅助的研究中，可复现性面临新的挑战。

传统研究的可复现性主要依赖于方法描述的精确性：你告诉别人你用了什么数据、什么模型、什么参数，别人就能重复你的分析。但当 AI 参与之后，问题变得复杂：

- 模型的版本会更新，同样的提示词在不同版本下可能产出完全不同的结果。
- 模型的输出有随机性，即使版本相同、提示词相同，两次运行的结果也可能不一样。
- 很多 AI 工具是黑箱，你无法精确描述它内部做了什么。

面对这些挑战，我在本书中提出的工作流强调三个原则：

1. **记录一切。**不仅记录结果，还记录过程：你用了什么提示词？模型返回了什么？你做了哪些筛选和修改？为什么做这些修改？
2. **保留原始数据。**AI 处理过的数据应该与原始数据分开存放，确保任何时候都能回溯到 AI 介入之前的状态。
3. **人工复核关键节点。**识别工作流中的“高风险节点”——一旦出错，代价很高的环节——并在这些节点强制进行人工复核。

这套工作流会贯穿全书，在每一章具体任务的讨论中都会体现。

### 1.3.3 3.3 必要的批判性

第三个目标是保持必要的批判性。这不是说我要“反对 AI”——恰恰相反，我是 AI 的重度用户，我的日常研究工作中大量使用各种 AI 工具。但正因为我是用户，我更清楚它的问题在哪里。

批判性体现在几个层面：

**对工具本身的批判。**大语言模型不是魔法，它有非常具体的能力边界和失败模式。理解这些边界和模式，是安全使用的前提。

**对使用方式的批判。**很多“最佳实践”其实是未经检验的假设。比如“提示词越详细越好”——真的吗？在什么条件下这个结论成立？有没有反例？

**对系统效应的批判。**当一项技术被广泛采用，它会改变整个系统的激励结构。AI 让写作更容易，但这会导致更多好研究，还是更多坏研究？投稿数量上升，审稿负担加重，审稿质量会不会下降？这些系统层面的问题，虽然个体研究者难以改变，但至少应该意识到。

## 1.4 四、这本书写给谁

在动笔之前，我认真思考过目标读者是谁。最终的定位是：所有在学术工作中与 AI 打交道的人。  
这个范围听起来很宽，但实际上是经过取舍的。

### 1.4.1 4.1 不同阶段的读者

**本科生和硕士研究生**可能是最直接的受益者。你们正处于学术训练的关键阶段，既要学习传统的研究方法，又要适应新工具的冲击。这本书希望帮你建立一个平衡的视角：AI 是有用的工具，但学术能力的核心——提出好问题、设计好研究、做出好判断——不会被工具取代。

**博士研究生和青年研究者**面临的挑战更具体：你们需要在有限的时间内产出高质量的研究，同时还要应对发表压力、资金压力、职业压力。AI 看起来像是缓解压力的捷径，但如果使用不当，它可能成为新的陷阱——你可能产出更多，但质量下降；你可能写得更快，但想得更浅。这本书希望帮你找到真正能提高研究质量的使用方式，而不是只追求表面的效率。

**成熟的研究者和教授**可能对 AI 工具本身已经有了自己的判断，但你们面临另一个问题：如何指导学生？如何制定团队的使用规范？如何评估 AI 辅助产出的研究成果？这本书的“五层次框架”和“团队协作”章节可能对你们特别有用。

**研究团队的管理者**——无论是实验室主任、项目负责人还是研究机构的领导——需要从更宏观的层面考虑 AI 的影响：如何制定政策？如何分配责任？如何平衡效率与风险？本书后半部分的讨论会涉及这些议题。

### 1.4.2 4.2 不同学科的读者

虽然我的主场是社会科学，但本书并不局限于社科读者。

**社会科学研究者**会发现这本书最贴近你的工作场景。从选题到文献综述，从数据收集到统计分析，从写作到投稿，每个环节都有具体的讨论。社科研究的特殊挑战——比如概念的模糊性、理论的多元性、数据的复杂性——也会被专门讨论。

**人文学科研究者**可能会觉得某些章节（比如统计分析）与你的工作距离较远，但其他章节——比如文献整理、概念辨析、写作表达——应该同样适用。AI 在人文研究中的角色可能与社科有所不同，但核心问题是相似的：如何利用工具而不被工具绑架？如何保持批判性而不是盲目接受？

**自然科学和工程学科的研究者**可能会发现，虽然具体的例子和场景与你的领域有差异，但底层的方法论讨论是通用的。特别是关于可复现性、数据管理、代码规范的讨论，对任何经验研究都有参考价值。

### 1.4.3 4.3 不同技术背景的读者

**对 AI 技术有深入了解的读者**可能会觉得某些技术解释过于基础。我的建议是跳过那些你已经熟悉的部分，直接进入方法论讨论。这本书的价值不在于教你“如何使用 ChatGPT”，而在于探讨“在学术研究中应该如何使用 AI”。

**对 AI 技术了解有限的读者**不用担心。本书不假设任何编程知识或技术背景。所有技术概念都会用通俗的语言解释，所有操作都会给出具体的步骤。如果你能用 Word 写论文、用浏览器搜文献，你就能跟上本书的节奏。

## 1.5 五、这本书不是什么

在说明这本书是什么的同时，我想明确它不是什么。

**这不是工具手册。**我不会逐一介绍市面上的 AI 工具，不会比较哪个工具“更好用”，也不会提供“N 个提示词模板让你效率翻倍”。工具更新太快，今天的教程明天就可能过时。我更关心的是那些不会过时的东西：思维方式、方法论、判断标准。

**这不是提示词大全。**提示词（prompt）确实很重要，但它被过度神秘化了。很多所谓的“高级提示词技巧”其实只是常识的重新包装。真正决定输出质量的，是你问题的理解、对任务的分解、对结果的评估——这些都发生在提示词之外。

这不是“AI 取代研究者”的宣言。我不认为 AI 会取代研究者，至少在可预见的将来不会。但我也认为 AI 只是“更快的搜索引擎”或“更智能的拼写检查器”。它是一种新型的工具，需要新型的使用方式。本书探讨的就是这种新型使用方式应该是什么样的。

这不是中立的技术介绍。我有自己的立场和偏好。我认为研究的核心是发现而不是写作，我认为可复现性比效率更重要，我认为批判性思考不能外包给机器。这些立场会影响本书的内容和论调。如果你不同意这些立场，你可能不会喜欢这本书——但我依然希望你读完它，因为不同意也是一种对话。

## 1.6 六、本书的结构与阅读建议

本书采用“多入口”设计，不同读者可以根据自己的需求选择不同的阅读路径。

### 1.6.1 6.1 整体结构

全书分为四个部分：

**第一部分（第 1–3 章）：基础认知。**这部分回答最基本的问题：AI 是什么？它能做什么、不能做什么？使用它有什么风险？如何建立正确的心理预期？建议所有读者都从这部分开始，即使你觉得自己已经“很了解 AI 了”——很多“了解”其实是误解。

**第二部分（第 4–7 章）：能力模块。**这部分按照“能力”来组织内容：信息压缩、结构化表达、代码与计算、知识管理。每种能力都是学术研究需要的，每种能力也都可以借助 AI 来增强。如果你对某种能力特别感兴趣，可以直接跳到对应章节。

**第三部分（第 8–12 章）：研究工作流。**这部分按照研究的“阶段”来组织内容：选题、文献、数据、分析、写作。如果你正处于研究的某个阶段，想知道“在这个阶段可以怎么用 AI”，可以直接跳到对应章节。

**第四部分（第 13–18 章）：层次与反思。**这部分提出“五层次框架”，讨论从个人使用到团队协作再到制度设计的不同层面。最后一章是全书的总结与反思。如果你是团队负责人或对 AI 政策感兴趣，这部分值得仔细阅读。

### 1.6.2 6.2 阅读路径建议

如果你是刚开始使用 AI 的新手：建议按顺序阅读，不要跳章。第一部分的基础认知特别重要——很多后面的讨论都建立在这些基础概念之上。

如果你已经有丰富的 AI 使用经验：可以快速浏览第一部分，然后根据自己的需求选择第二部分或第三部分的具体章节。第四部分的“五层次框架”可能会给你新的视角。

如果你是带团队的负责人：建议重点阅读第四部分，然后根据团队的具体需求选读其他章节。你可能需要的不是自己学会所有技巧，而是建立一套团队可以遵循的规范 and 标准。

如果你只是想快速了解本书的核心观点：可以只读第 1 章（基本原则）、第 3 章（提示词不是方法论）和第 18 章（终章）。这三章浓缩了全书最重要的思想。

### 1.6.3 6.3 每章的结构

每一章都采用相似的结构：

1. **问题引入**：这一章要解决什么问题？为什么这个问题重要？
2. **核心讨论**：理论分析、方法论讨论、常见误区剖析
3. **实践指南**：具体的操作步骤、工作流示例、提示词参考
4. **案例分析**：真实或仿真的案例，展示如何在实践中应用
5. **反思与延伸**：这一章的局限性、开放问题、进一步阅读建议

你不必每次都按顺序读完一整章。如果你时间有限，可以先读“问题引入”和“反思与延伸”，快速把握要点；如果你需要立刻开始工作，可以直接跳到“实践指南”；如果你想深入思考，可以专注于“核心讨论”。

## 1.7 七、一些重要的声明

在正式开始之前，我想做几个声明。

### 1.7.1 7.1 关于时效性

AI 领域变化极快。这本书写作于 2024 年末到 2025 年初，其中提到的具体工具、功能、政策都可能已经更新。我会尽量确保书中的信息在出版时是准确的，但无法保证你阅读时依然准确。

不过，这也是我强调“方法论”而非“工具介绍”的原因。具体工具会变，但思考问题的方式不会轻易过时。如何评估工具的可靠性、如何设计人机协作的流程、如何在效率与质量之间取得平衡——这些问题在什么时候都是相关的。

### 1.7.2 7.2 关于局限性

我不是 AI 专家，不是计算机科学家，也不是技术哲学家。我的背景是社会科学研究。这意味着本书的视角必然有局限：

- 技术细节可能不够深入。如果你想了解大语言模型的内部原理，应该去读专业的技术文献。
- 社科以外的学科可能覆盖不够。我会尽量涵盖不同学科的例子，但我对某些领域的了解确实有限。
- 文化语境可能有偏差。我主要在中文和英文学术环境中工作，对其他语言和文化的学术传统了解有限。

我认为诚实地承认局限性是学术写作的基本态度。如果我假装自己什么都懂，读者反而无法判断哪些内容可信、哪些需要进一步验证。

### 1.7.3 7.3 关于 AI 辅助写作

这是一个无法回避的问题：这本书本身是不是用 AI 写的？

答案是：部分是。

更准确地说，我在写作过程中使用 AI 来做以下事情：

- 初稿的部分段落由 AI 生成，然后我进行大幅修改、重组、补充。
- 一些技术概念的解释参考了 AI 的输出，但核心观点和论证是我自己的。
- 文字润色和错别字检查使用了 AI 辅助。
- 某些案例的框架由 AI 生成，但具体细节是我补充或编造的。

我不认为这是值得隐瞒的事情。首先，这是我在书中倡导的“人机协作”的实践——如果我自己都不用 AI 来写作，这本书的建议就缺乏实践基础。其次，这也是对可复现性承诺的延伸——我愿意披露我的写作过程，让读者知道他们在读什么。

但我想强调两点：第一，本书的核心论点、整体结构、关键判断都是我的，不是 AI 的。AI 可以帮助生成文字，但不能帮我决定“什么值得说”。第二，所有重要的事实陈述和引用都经过我的人工核实。我前面讲的那个“失败的文献综述”的教训，我没有忘记。

### 1.7.4 7.4 关于争议性观点

本书包含一些可能引发争议的观点，比如：

- 很多所谓的“提示词工程”是被过度包装的简单技巧
- “效率提升”不应该是使用 AI 的主要理由
- 学术界对 AI 的某些恐惧是合理的，不应该被嘲笑为“守旧”
- 当前的很多“AI 科研工具”在商业利益驱动下夸大了自己的能力

这些观点不是随意发表的情绪，而是基于我对文献、实践和逻辑的综合判断。但判断可能是错的。如果你不同意某个观点，我欢迎你通过本书的 GitHub 仓库提出 issue，我们可以进行公开讨论。

## 1.8 八、为什么选择开源

这本书从一开始就是以开源项目的形式写作的。这个选择是刻意的，原因有几个。

### 1.8.1 8.1 可复现与可验证

学术研究的核心价值之一是可复现性：别人可以重复你的工作，验证你的结论。传统的学术出版物在这方面做得还可以——你可以看到论文的方法描述、数据来源、分析代码。但书籍出版往往是不透明的：你看到的只是最终成品，不知道作者是如何得出那些结论的。

开源改变了这一点。在本书的 GitHub 仓库里，你可以看到：

- 每一章的写作历史和修改记录
- 我使用的提示词和 AI 输出的原文
- 读者提出的质疑和我的回应
- 错误的勘误和更正

这不仅是对读者的尊重，也是对自己的约束。当你知道自己的一切都会被公开审视，你会更加谨慎。

### 1.8.2 8.2 持续更新

AI 领域变化太快，一本传统出版的书籍在出版时可能已经过时。开源允许持续更新：当新工具出现、旧工具下架、某个建议被证明有问题，我可以及时修改。读者永远可以访问最新版本。

当然，这也带来版本管理的问题。我会维护清晰的版本号和更新日志，确保读者知道自己读的是哪个版本，以及这个版本与之前版本有什么区别。

### 1.8.3 8.3 社区协作

一个人的知识和经验总是有限的。开源允许社区协作：如果你发现某个错误、有更好的案例、想补充某个领域的视角，你可以直接提交贡献。这本书不仅仅是我写的，也是所有贡献者共同创作的。

我承诺会认真对待每一个贡献，无论是批评还是建议。当然，最终的编辑权在我手里——这是为了保持全书的一致性和质量——但贡献者会在书中得到致谢。

### 1.8.4 8.4 价值观的表达

最后，选择开源也是一种价值观的表达。我相信知识应该是开放的，尤其是关于如何更好地生产知识。如果我写一本关于“AI 如何让学术研究更透明、更可复现”的书，然后把它锁在付费墙后面，这在逻辑上是自相矛盾的。

当然，开源不等于“没有成本”。维护这个项目需要时间和精力，我也需要生存。如果你觉得这本书对你有价值，可以通过购买实体书（如果出版的话）、赞助 GitHub 项目、或者简单地在社交媒体上分享来支持我。

## 1.9 九、我们正处于什么样的时刻

在结束这篇序章之前，我想谈谈我对当前时刻的理解。这不是技术分析，而是一种历史感——一种对“我们站在哪里”的判断。

### 1.9.1 9.1 炒作周期的高峰与低谷

如果你熟悉 Gartner 的技术炒作周期 (Hype Cycle)，你会知道每一项新技术都会经历类似的过程：先是过度乐观的炒作期，然后是幻灭期的低谷，最后才是稳定的应用期。大语言模型显然还处于炒作期的尾声——铺天盖地的报道开始减少，“AI 会取代一切”的论调也不如以前那么响亮。



但这并不意味着 AI 不重要了。恰恰相反，真正的影响往往在炒作退潮之后才开始显现。互联网的炒作期在 2000 年泡沫破灭后结束，但互联网对社会的真正改变发生在之后的二十年。我预感大语言模型也会是类似的轨迹：当媒体不再每天报道它，当人们不再把它当作神奇的新玩具，它才会真正融入我们的工作流程，产生深远而隐秘的影响。

这也是我选择在这个时候写这本书的原因。炒作期的内容往往过于狂热或过于恐惧，都难以提供冷静的分析。而在炒作退潮、实际应用逐渐铺开的阶段，才是最需要方法论指导的时候。

## 1.9.2 9.2 学术界的特殊处境

学术界对 AI 的态度一直很矛盾。一方面，很多研究者是 AI 技术的直接创造者和研究者——如果没有学术界的贡献，今天的大语言模型根本不会存在。另一方面，学术界又是最可能被 AI 冲击的领域之一——阅读、写作、分析这些 AI 擅长的任务，恰恰是学术工作的核心。

这种矛盾导致了两种极端的反应。一些人完全拥抱 AI，把它当作解放生产力的神器，迫不及待地用它来加速每一个环节。另一些人则极度警惕，视 AI 为学术诚信的威胁，呼吁全面禁止。

我认为这两种极端都是有问题的。完全拥抱忽视了风险，而完全禁止则忽视了现实——学生和研究者已经在用 AI 了，禁止只会把使用推向地下，让问题更难管理。我们需要的是第三条路：承认 AI 会被使用，然后认真思考“如何使用才是负责任的”。

## 1.9.3 9.3 一场正在发生的范式转移

回顾科学史，每一次重大工具的引入都会带来研究范式的转移。显微镜让我们看到了微观世界，计算机让我们能处理海量数据，互联网让我们能即时获取全球文献。每一次转移都伴随着担忧和争议，但最终都被吸收进了“正常科学”的实践中。

大语言模型可能正在引发又一次这样的转移。它不只是“更快的工具”，而是一种新型的认知伙伴——它能理解（某种意义上的）语言，能生成（某种意义上的）知识，能与研究者进行（某种意义上的）对话。这是之前任何工具都做不到的。

当然，这种“理解”“知识”“对话”都需要打引号。模型是否真的理解任何东西，是一个哲学上有争议的问题。但无论如何，它的行为——它能做什么——是实实在在的。而正是这些行为，正在改变学术研究的实践。

这本书的写作，正是处于这场范式转移的早期阶段。我不能告诉你转移的终点在哪里，但我希望能帮你更清醒地认识到：转移正在发生，而你需要为此做好准备。

## 1.9.4 9.4 个人选择的重要性

面对技术变革，个体往往感到无力：趋势是不可阻挡的，个人能做什么呢？

但我想强调的是，个人选择依然重要。技术不是自动生效的，它需要被具体的人在具体的场景中采用。你选择如何使用 AI，会影响到你的研究质量；你的选择汇聚起来，会影响到整个学术社区的规范。

如果每个人都选择“快速产出”而忽视“仔细核实”，学术界就会充斥着低质量的研究。如果每个人都选择“隐藏使用”而不是“透明披露”，学术诚信的边界就会变得模糊。但反过来，如果足够多的人选择负责任的使用方式，并且公开倡导这种方式，新的规范就有可能形成。

这本书，从某种意义上说，就是我的选择——我选择花时间思考这些问题，并且把思考的结果分享出来。我希望它能帮助你做出你自己的选择。

## 1.10 十、致谢

这本书的写作得到了很多人的帮助，我想在这里表达感谢。

感谢我的同事和学生，他们在日常工作中与我分享了各种 AI 使用的经验和困惑。很多章节的灵感直接来自于我们的对话。

感谢那些在 GitHub 上提交 issue 和建议的读者（你们的名字会出现在贡献者列表中）。开源写作的意义就在于集体智慧的汇聚。

感谢那些写过“AI 科研指南”的前辈。虽然我在本章中批评了很多现有内容的不足，但我并不否认它们的价值——正是因为有了它们，我才能知道还缺什么，才能尝试填补空白。

感谢我的家人，他们容忍了我在电脑前度过的无数个夜晚。

最后，感谢你，读者。一本书只有在被阅读的时候才真正存在。你选择花时间读这本书，就是对我工作的最大肯定。

## 1.11 十一、写在最后

动笔之前，我犹豫了很久。

犹豫不是因为不知道写什么——相反，我有太多想说的。犹豫是因为担心自己没有资格说。我不是 AI 领域的权威，不是有几十年经验的老教授，甚至不是一个特别成功的学者。我凭什么写这本书？

后来我想通了：正因为我不是权威，我才可能写一本真正有用的书。权威往往离实践太远，他们的建议虽然“正确”，但普通研究者很难执行。而我，就是一个普通研究者。我每天都在用 AI 做研究，每天都在踩坑和填坑。我写的不是“应该怎么做”，而是“我是怎么做的，以及我从错误中学到了什么”。

这本书不会解决所有问题。AI 与学术研究的关系还在快速演变，很多问题现在还没有答案。但我希望它能提供一个起点：一个思考的起点，一个对话的起点，一个改进的起点。

如果你读完这本书，产生了一些想法——无论是同意、反对还是困惑——我希望你能告诉我。这本书是开源的，意味着它永远是未完成的。你的反馈会让它变得更好。

感谢你选择这本书。让我们开始吧。

## 2 第 1 章 AI 能做什么，不能做什么

AI 最擅长的不是“正确”，而是“像”。它能在语言上高度拟合学术表达的样子，能快速压缩文本、重写段落、生成结构化输出，但这并不等于它理解或验证了事实。研究者要先看清这一点：AI 是生成式系统，不是知识库、也不是裁判。

一个实用的判断方式是把 AI 能力分成四类：压缩、改写、重组、推理。压缩指摘要与信息提取；改写指语言润色与风格转换；重组指把散乱信息结构化；推理则是它最容易被高估的能力，因为模型擅长“构造合理解释”，却未必能承担“正确推导”的责任。

因此，AI“很强但不可靠”的根源在于：它更像一个高水平写作者，而不是可靠的事实校验器。你可以让它生成思路、提出假设、搭建框架，但关键环节必须回到人类研究者的验证流程里。把 AI 当成“高效助手”，而不是“权威来源”，这是这本书的首要原则。

## 3 第 2 章 幻觉、偏差、泄露：三类核心风险

AI 带来的最大问题不是“效率”，而是“错误的效率”。三类风险贯穿所有研究流程：幻觉、偏差、泄露。它们不只是技术问题，更是方法论和伦理问题。

幻觉是模型在不确定时仍然给出流畅答案的倾向。它在科研中的危害不在于“出现错误”，而在于“错误看起来合理”。这会侵蚀研究者的判断力，尤其在文献综述、理论归纳、背景介绍等环节，幻觉常以“自信口吻”呈现，导致难以识别。

偏差来自模型训练数据与对齐机制，会在不知不觉中渗入研究。比如对某些群体的刻板印象、对某些研究范式的偏好，都会影响输出。研究者必须意识到：AI 的“中立语气”并不意味着“中立立场”。

泄露则是更现实的风险。把未发表的研究数据、敏感信息或受限数据直接输入模型，会带来合规与伦理问题。即便使用本地模型，也要考虑数据治理与权限边界。使用 AI 前先回答一个问题：这份数据能否被任何人看到？如果答案是否定的，就不应该直接交给模型处理。

## 4 第 3 章 提示词不是方法论

### 4.1 一、一场关于提示词的迷信

2024 年春天，我参加了一个 AI 辅助科研的工作坊。主讲人是一位在社交媒体上颇有影响力的“AI 效率专家”，他用了整整两个小时讲解“学术研究的终极提示词模板”。

他的演示确实令人印象深刻：输入一个精心设计的提示词，模型就能输出结构完整的文献综述框架；换一个模板，就能生成看起来专业的研究假设；再换一个，还能产出像模像样的方法论描述。现场的研究生们兴奋地拍照记录，仿佛找到了学术写作的捷径。

但当我仔细审视那些输出时，一种熟悉的不安感涌上心头。那些文献综述框架虽然结构漂亮，但核心论点是空洞的；那些研究假设虽然表述规范，但缺乏对真实研究问题的深入理解；那些方法论描述虽然术语正确，但与具体研究场景脱节。

更让我担忧的是提问环节。一位博士生问：“我的研究是关于社交媒体对青少年心理健康的影响，能不能给我一个更具体的提示词？”主讲人的回答是：“你可以在我的模板里把‘研究主题’替换成你的具体领域就行了。”

这个回答让我意识到，我们正在见证一场关于提示词的集体迷信。人们把提示词当成了某种魔法咒语——只要念对了咒语，研究的难题就会迎刃而解。但真正的问题是：如果研究者本身不清楚自己要研究什么、为什么研究、如何研究，再精妙的提示词也只能产出精致的空壳。

### 4.2 二、提示词能做什么，不能做什么

让我们先诚实地面对提示词的能力边界。

#### 4.2.1 2.1 提示词确实有用

我不是在说提示词毫无价值。恰恰相反，好的提示词确实能显著提升 AI 输出的质量。它的作用主要体现在三个方面。

**第一，约束输出格式。**如果你需要模型输出一个表格、一份大纲、或者按照特定结构组织的文本，提示词可以明确这些要求。比如“请以 markdown 表格形式呈现，包含作者、年份、主要发现、方法论四列”——这种格式约束是有效的，因为它本质上是在给模型一个模板。

**第二，设定角色与语境。**告诉模型“你是一位熟悉社会科学方法论的研究者”或“请以学术论文的语言风格回答”，可以帮助模型调整输出的语气和专业程度。这类似于告诉一个通才“现在请用专家的方式来回答”——虽然不能让通才变成真正的专家，但至少能让回答更像是专家会说的话。

**第三，分解复杂任务。**把一个大问题拆成多个小问题，每次只让模型处理一个环节，这确实能提高输出质量。比如先让模型“列出这篇论文的核心论点”，再让它“分析每个论点的证据支撑”，最后让它“评估整体论证的逻辑强度”——这种分步处理比一次性要求“请全面分析这篇论文”效果更好。

这三种作用是真实的，也是值得学习的。问题在于，很多提示词教程把这些基本技巧包装成了某种神秘的“prompt engineering”，仿佛只要掌握了正确的咒语，就能解锁 AI 的隐藏能力。

#### 4.2.2 2.2 提示词不能做什么

更重要的是认识到提示词的边界。有些东西是再好的提示词也无法弥补的。

**第一，提示词无法提供研究者自己没有的判断力。**如果你不知道什么是好的研究问题，提示词不会帮你识别出好的研究问题。如果你不理解某个理论框架的核心逻辑，提示词不会让模型的解释变得对你有意义。AI 可以生成看起来像是好问题、好框架的东西，但判断它们是否真的好，仍然需要研究者自己的专业素养。

我见过太多这样的情况：研究生用提示词生成了一堆“研究问题选项”，然后问导师“您觉得哪个好”。这个问题本身就暴露了问题所在——如果你需要别人来判断哪个研究问题更好，那么使用提示词生成这些问题并没有让你在研究能力上有任何进步。

**第二，提示词无法保证输出的正确性。**无论你的提示词写得多么精确，模型仍然可能产生幻觉、犯事实错误、或者给出逻辑上有漏洞的论证。很多提示词模板声称能“减少幻觉”或“提高准确性”，但这些说法大多缺乏严格验证。即使某个提示词在特定场景下确实降低了错误率，你也无法事先知道当前这次输出是否属于那“降低的”部分还是“剩余的”错误部分。

**第三，提示词无法替代研究过程本身。**学术研究不是输入问题、输出答案的过程。它涉及反复的阅读与思考、假设的形成与修正、数据的收集与分析、论证的构建与检验。这些过程需要时间，需要投入，需要走弯路然后纠正方向。提示词可以在某些环节提供辅助，但它无法压缩研究过程本身所需要的认知劳动。

有一次，一位学生得意地告诉我，他用一个精心设计的提示词，让 ChatGPT“帮他完成了整个文献综述”。我让他随机挑选其中引用的三篇论文，说说每篇论文的核心贡献和方法论特点。他答不上来。这不是因为提示词不够好，而是因为提示词从根本上不可能替代真正阅读和理解文献的过程。

### 4.2.3 2.3 核心区分：流程辅助 vs. 判断替代

理解提示词的一个关键是区分两类不同的需求：流程辅助和判断替代。

**流程辅助**指的是那些规则明确、可重复、不需要太多专业判断的任务。比如：把一份英文摘要翻译成中文，按照特定格式整理参考文献，从一段文本中提取关键词，把会议记录整理成结构化的要点。这些任务的“正确答案”相对客观，可以被验证，而且验证的成本较低。在这类任务上，提示词确实能发挥显著作用。

**判断替代**指的是那些需要专业知识、涉及价值判断、或者依赖语境理解的任务。比如：评估一个研究假设是否有价值，判断一篇论文的方法论是否合理，决定某个论点是否站得住脚，选择研究设计中的关键参数。这些任务没有“标准答案”，正确性高度依赖于研究者的专业素养和对具体情境的理解。在这类任务上，提示词能做的非常有限——它可以让模型输出“像”是专业判断的东西，但不能保证那真的是正确的判断。

很多对提示词的误解，源于没有认清这个区分。人们把在“流程辅助”任务上看到的效果，错误地外推到了“判断替代”任务上。他们想：既然提示词能让翻译质量提高那么多，那应该也能让研究设计的质量提高吧？但这两类任务有本质区别。

## 4.3 三、为什么提示词被过度神化

既然提示词的边界如此明显，为什么关于它的迷信如此流行？我认为有几个原因。

### 4.3.1 3.1 简单问题的诱惑

人类天生偏好简单的解决方案。面对“如何做好学术研究”这个复杂问题，“学会写好提示词”是一个极具吸引力的答案——它具体、可操作、而且见效快。相比之下，“深入理解你的研究领域”“培养批判性思维”“在反复试错中积累经验”这些答案虽然更接近真相，但听起来既抽象又费力。

提示词模板满足了人们对“速成攻略”的渴望。收藏一个“万能提示词”比花三个月读透一个研究领域的文献要轻松得多。更诱人的是，模型确实会给出看起来不错的回应——它不会说“这个问题太复杂，我回答不了”，它会给你一个结构完整、语言流畅的输出。这种即时的正反馈强化了“提示词就是答案”的错觉。

### 4.3.2 3.2 商业利益的驱动

我们不能忽视围绕“提示词工程”已经形成的商业生态。有人卖课程，有人卖模板，有人靠分享“提示词技巧”积累社交媒体影响力。这些商业模式都依赖于一个前提：提示词是一种需要专门学习的技能，而且学会了就能获得显著回报。

这不是说所有提示词教程都是骗人的。有些确实提供了有价值的思路和技巧。但商业激励确实会导致系统性的夸大。教你“这个提示词能让你的论文写作效率提升 300%”“比你”这个技巧能在某些特定场景下略微改善输出质量”更容易吸引点击和付费。

### 4.3.3 3.3 对 AI 能力的误解

很多对提示词的迷信，根源在于对大语言模型本身能力的误解。

有一种常见的心智模型是：AI“知道”很多东西，问题只是如何“问对问题”把这些知识引出来。按照这个逻辑，提示词就像是打开宝库的钥匙——只要找到正确的钥匙，就能获取里面的宝藏。

但这个心智模型是错误的。大语言模型不是一个装满知识等待被提取的容器，而是一个被训练来预测“给定前文，下一个词最可能是什么”的系统。它在生成输出时，并没有在“搜索”某个内部数据库，而是在基于统计规律“构建”一个最可能的延续。

这意味着什么？意味着模型的输出质量不仅取决于你怎么问，更取决于它在训练时见过什么样的数据、这些数据的质量和偏向是什么、以及你的问题在多大程度上落在它的“能力范围”之内。改变提示词可以影响输出，但无法突破这些更根本的限制。

### 4.3.4 3.4 可观察性偏差

还有一个更微妙的原因：提示词是可见的，而研究能力是不可见的。

当一个研究生使用同样的提示词却得到比你更好的结果时，你看不到的是：他在使用提示词之前已经花了很多时间理解那个研究领域，他在评估输出时运用了怎样的专业判断，他如何在多轮对话中逐步修正和深化最初的输出。你能看到的只是那个“提示词”，于是你会误以为差别在于提示词本身。

真正起作用的往往是那些不可见的东西：对问题的清晰理解、对质量的准确判断、对输出的批判性评估。但这些东西难以传授、难以包装、也难以售卖。提示词之所以成为焦点，部分原因是它恰好是整个过程中最容易观察和复制的部分。

## 4.4 四、从“提问技巧”走向“研究系统”

如果提示词不是答案，那什么才是？我的建议是：把注意力从“如何问好一个问题”转向“如何构建一个可靠的研究系统”。

### 4.4.1 4.1 什么是“研究系统”

所谓研究系统，是指一套可重复、可检验、可追溯的工作流程，它规定了：

- **输入什么材料**：你用什么数据、什么文献、什么信息作为起点
- **执行什么任务**：你要完成哪些具体的处理和分析步骤
- **如何校验输出**：你用什么标准和方法来检查结果的质量
- **怎样记录过程**：你如何保留足够的信息以便日后追溯和复现

注意，这个定义中没有提到“提示词”。提示词可以是这个系统的一部分，但只是很小的一部分。系统的核心不在于你和 AI 说了什么话，而在于这些对话嵌入在怎样的工作流程中。

让我用一个具体例子来说明。假设你的任务是“整理某个领域的核心文献”。

**没有系统的做法**是：打开 ChatGPT，输入“请推荐关于 XX 领域的重要文献”，然后把输出保存下来。这个做法的问题是显而易见的：你不知道模型推荐这些文献的依据是什么，你无法验证这些推荐的质量，一个月后你可能完全记不起这份列表是怎么来的。

**有系统的做法**可能是这样的：

1. 首先，确定文献来源（比如 Web of Science、Scopus、Google Scholar），并记录检索策略（关键词、时间范围、筛选条件）。
2. 其次，下载初筛结果（比如 100 篇论文的题目和摘要），存档为原始数据。
3. 然后，用 AI 辅助进行第一轮分类：把论文按主题聚类，识别高频引用的关键作者和概念。在这个步骤中，你可以使用提示词，但关键是记录你使用的具体提示词和模型版本。
4. 接着，人工审核 AI 的分类结果，修正错误，补充遗漏。这个步骤不能省略，因为它是你真正建立对领域理解的过程。

5. 然后，针对每个主题聚类，精读 3–5 篇代表性论文，记录你自己的理解和评价。
6. 最后，整理输出一份文献地图，包括主要主题、核心论文、关键争议、研究空白。
7. 全程保留版本记录：每次修改都有时间戳，可以追溯任何结论是怎么得出的。

在这个系统中，AI 确实参与了某些环节（比如第 3 步的初步分类），但它的角色是明确的、有限的、可审计的。更重要的是，即使完全不用 AI，这个系统依然成立——AI 只是让某些步骤更高效，但没有改变系统的基本结构。

#### 4.4.2 4.2 系统的核心特征

一个好的研究系统应该具备几个核心特征。

**可重复：**如果你或你的同事遵循同样的流程，应该能够得到相似（虽然不必完全相同）的结果。这意味着流程需要足够具体，关键参数需要被记录，随机性需要被控制或至少被记录。

**可检验：**系统的每个环节都应该有某种质量检查的方式。不是等到最后才发现问题，而是在过程中就能发现和纠正问题。比如，AI 生成的文献分类应该通过抽查来验证，而不是默认接受。

**可追溯：**事后应该能够回答“这个结论是怎么得出的”。这需要充分的记录：使用了什么数据，经过了哪些处理，做了哪些决策，依据是什么。当 AI 参与时，这一点尤其重要——你需要记录使用的模型、版本、提示词、输出。

**容错：**系统应该假设会出错，并在设计中考虑如何发现和纠正错误。冗余检查、交叉验证、人工复核——这些机制不是“额外工作”，而是保证质量的必要投入。

#### 4.4.3 4.3 AI 在系统中的位置

在一个设计良好的研究系统中，AI 的位置应该是明确的和受限的。

**明确意味着：**你清楚 AI 在哪些环节参与、执行什么任务、产出什么结果。不是“我用 AI 帮忙做了一些事情”，而是“AI 在步骤 3 执行了初步分类，在步骤 5 协助了文本润色”。

**受限意味着：**AI 不应该出现在那些需要核心判断的关键节点上，或者即使出现也必须有严格的人工复核。识别哪些节点是“关键的”，本身就是设计系统的重要工作。

一个有用的问题是：如果 AI 在这个环节犯了错，后果是什么？如果后果严重且难以通过后续步骤发现，那这个环节就需要额外的保护——要么不使用 AI，要么必须有独立的验证机制。

另一个有用的问题是：这个环节的质量，我能通过什么方式检验？如果你无法独立验证 AI 的输出质量（比如因为你自己不具备相关知识），那就不应该在这个环节依赖 AI——因为你没有办法知道它是否做对了。

### 4.5 五、建立自己的工作流原则

基于以上讨论，我想提出几个构建 AI 辅助研究工作流的核心原则。这些原则不是具体的提示词模板，而是设计工作流程时应该遵循的指导思想。

#### 4.5.1 5.1 任务拆解原则

**核心思想：**把大任务分解成小任务，把模糊任务转化为具体任务。

大语言模型在处理边界清晰的小任务时表现更好。“帮我写一篇关于气候变化政策的综述”是一个糟糕的任务描述，因为它包含太多隐含的子任务：确定综述范围、检索相关文献、筛选核心论文、归纳主要观点、识别研究空白、组织成文……每一个子任务都有自己的复杂性。

更好的做法是显式地拆解：

- 任务 1：明确综述的具体问题（关于气候变化政策的什么？碳税的经济效应？还是国际协调机制的有效性？）
- 任务 2：确定检索策略（在哪些数据库检索？用什么关键词？时间范围是多少？）



- 任务 3：初步筛选（根据题目和摘要，排除明显不相关的文献）
- 任务 4：深入阅读核心文献（精读 20–30 篇最相关的论文）
- 任务 5：归纳和综合（提取主要发现，识别共识和争议）
- .....

在这个拆解中，有些任务适合 AI 辅助（比如任务 3 的初步筛选），有些则必须由人类主导（比如任务 1 的问题界定和任务 4 的深入阅读）。拆解本身就是在明确 AI 的角色边界。

**实践建议：**在使用 AI 之前，先用纸和笔（或者简单的文本文件）把你的任务拆解成尽可能小的单元。问自己：这个单元的输入是什么？期望的输出是什么？我如何判断输出的质量？

## 4.5.2 5.2 层级输出原则

**核心思想：**不要期望一次性得到完美输出，而是通过多轮迭代逐步精化。

很多人使用 AI 的方式是：输入一个提示词，得到一个输出，如果不满意就换一个提示词再试。这种方式把每次交互都当作独立的事件，没有利用对话的累积性。

更有效的方式是层级式的：

- **第一层：粗略轮廓。**先让 AI 给出一个粗略的框架或方向。这个阶段的目标不是获得可用的输出，而是快速探索可能性。
- **第二层：细化某个方向。**在粗略轮廓中选择一个值得深入的方向，让 AI 进一步展开。这时可以提供更多具体信息和约束条件。
- **第三层：具体化和验证。**对细化后的内容进行具体化，同时开始验证关键信息的准确性。这个阶段经常需要跳出 AI 对话，去查阅原始资料。
- **第四层：整合和润色。**把经过验证的内容整合成最终输出，进行语言和格式上的润色。

这个过程不是线性的。你可能在第三层发现第一层的方向选错了，需要回退重来。但层级化的思路保证了每一步都有明确的目标，错误能够被较早发现。

**实践建议：**在每一层结束时，暂停下来问自己：这个输出是否足够准确，值得在它的基础上继续深入？如果你发现自己在第三层才发现第一层就有根本性问题，下次就要考虑在第一层投入更多验证工作。

## 4.5.3 5.3 验证机制原则

**核心思想：**任何 AI 输出都需要验证，验证的力度应该与错误的后果成正比。

验证不是可选的附加步骤，而是使用 AI 的必要组成部分。问题是验证需要成本，所以需要根据风险来分配验证资源。

**低风险任务**（错误易发现，后果可逆，成本低）：可以采用抽查式验证。比如 AI 帮你整理了一份 100 条的引用列表，你可以随机抽查 10 条来判断整体质量。

**中风险任务**（错误较隐蔽，后果有影响，成本中等）：需要系统性验证。比如 AI 帮你总结了 10 篇论文的核心论点，你应该每一篇都回到原文核对，确保概括准确。

**高风险任务**（错误难发现，后果严重，成本高）：需要独立验证。比如 AI 给出了某个统计方法的解释，你应该查阅教科书或权威资料独立确认，而不是仅仅让同一个 AI“再解释一遍”。

有一种常见的错误是用 AI 来验证 AI 的输出——让同一个模型检查自己之前的回答，或者换一个提示词让它“确认”之前的结论。这种做法几乎没有验证价值，因为模型的偏差是系统性的，它不会通过重复访问而消失。

**实践建议：**在开始一个任务之前，先问自己：如果 AI 在这里犯错，我会怎么发现？如果你答不上来，说明这个任务可能不适合交给 AI，或者你需要先设计一个验证机制。

## 4.5.4 5.4 版本记录原则

**核心思想：**保留足够的信息，使得任何结论都可以追溯其来源。

这个原则在传统研究方法中已经很重要（记录数据来源、分析代码、决策理由），在 AI 辅助研究中更加重要，因为 AI 增加了一个不透明的环节。

需要记录的信息包括：

- **模型信息**：使用的模型名称和版本（比如 GPT-4-turbo-2024-04-09），使用的参数设置（比如 temperature）
- **输入信息**：完整的提示词，提供给模型的上下文材料
- **输出信息**：模型的完整输出（不仅仅是你使用的部分）
- **处理信息**：你对输出进行了哪些修改、筛选、整合
- **验证信息**：你进行了哪些验证，验证的结果是什么

这听起来像是大量额外工作，但实际上可以通过工具和习惯来简化。很多 AI 对话工具允许导出完整历史；你可以建立标准化的文件夹结构来组织这些记录；关键决策点可以用简单的笔记来记录理由。

**实践建议**：至少做到这一点——每次使用 AI 完成一个重要任务，事后能够回答“这个结论是基于什么输入、经过什么处理、做过什么验证”。如果你发现自己答不上来，说明记录工作需要加强。

### 4.5.5 5.5 边界意识原则

**核心思想**：清晰地认识到哪些任务适合 AI 辅助，哪些不适合。

这个原则是前面所有原则的基础。如果你不知道 AI 的能力边界在哪里，就无法正确地设计任务拆解、输出层级、验证机制。

一些经验性的指导：

**适合 AI 辅助的任务特征**：– 规则明确，“正确答案”相对客观 – 验证成本低（你可以较容易地检查输出质量）– 错误后果可控（即使出错也可以补救）– 任务可分解，每个子任务边界清晰

**不适合 AI 辅助的任务特征**：– 需要深度专业判断 – 你自己无法独立验证输出质量 – 错误后果严重且难以察觉 – 任务高度依赖特定语境和隐性知识

当然，这不是非黑即白的分类。很多任务介于两者之间，需要具体分析。关键是培养这种分析习惯：在把任务交给 AI 之前，先思考这个任务的特征，评估 AI 可能带来的价值和风险。

**实践建议**：保持一个“AI 使用日志”，记录你使用 AI 的场景、效果、遇到的问题。一段时间后，你会对自己的使用模式有更清晰的认识，知道哪些场景值得继续探索，哪些应该避免。

## 4.6 六、一个完整的例子

让我用一个具体的例子来说明如何应用这些原则。假设你是一位社会科学研究生，你的导师让你“调研一下最近五年关于算法歧视的实证研究”。

### 4.6.1 6.1 没有系统的做法

你打开 ChatGPT，输入：“请帮我整理最近五年关于算法歧视的实证研究，包括主要发现和方法论。”

模型给出了一份看起来不错的列表，包含了十几项研究的简要描述。你把这份列表整理一下，交给了导师。

两周后，导师问你：“你提到的那个 ProPublica 关于 COMPAS 的研究，他们具体的分析方法是什么？有什么局限性？”你答不上来，因为你从来没有读过那篇原始报告。

### 4.6.2 6.2 有系统的做法

#### 第一步：明确任务边界（任务拆解）

你首先问自己几个问题：– “最近五年”是指哪个时间范围？（确定：2019–2024）– “算法歧视”的定义是什么？包括哪些类型？（确定：主要聚焦于机器学习算法在信贷、招聘、刑事司法等领域的歧视性结果）– “实证研究”是指什么？（确定：包括真实数据分析、审计研究、实验研究，不包括纯理论论文）– 导师期待的产出是什么？（确定：一份综述报告，约 3000 字，需要包括研究方法的比较分析）

#### 第二步：设计检索策略

你决定从两个来源检索文献：– 学术数据库：Web of Science，使用关键词“algorithmic bias” OR “algorithmic discrimination” AND “empirical” – 补充来源：Google Scholar，用于捕捉可能不在 WoS 中的跨学科研究和工作论文

你记录了检索时间、检索词、检索条件、结果数量。

### **第三步：初步筛选（AI 辅助）**

从检索中获得约 200 篇文献的题目和摘要。你把这些导出为一个文件，然后使用 AI 进行第一轮筛选。

提示词：“以下是 200 篇关于算法歧视的论文摘要。请帮我识别其中属于‘实证研究’的论文（即使用真实数据或实验方法研究算法歧视现象的研究），并按照研究领域（信贷、招聘、刑事司法、医疗、其他）分类。”

AI 给出了一个分类列表，标注了约 80 篇可能是实证研究的论文。

### **第四步：验证和调整（验证机制）**

你随机抽取 10 篇 AI 标注为“实证研究”的论文，快速浏览摘要验证分类是否正确。发现 8 篇分类准确，2 篇其实是综述性文章被误标。

你又抽取 5 篇 AI 标注为“非实证研究”的论文，检查是否有遗漏。发现 1 篇其实是实证研究但被遗漏了。

基于这个抽查结果，你估计 AI 的分类大致可靠，但存在约 20% 的错误率。你决定对所有 80 篇“实证研究”的摘要进行人工快速审核，最终确定约 65 篇进入下一轮。

### **第五步：深入阅读（不使用 AI）**

你从 65 篇中选择 20 篇代表性论文进行精读。选择标准包括：高被引、方法论创新、涵盖不同领域。

这个步骤没有使用 AI。你阅读每篇论文的全文，记录研究问题、数据来源、分析方法、主要发现、局限性。这是建立真正理解的过程，不可压缩。

### **第六步：归纳综合**

你基于深度阅读的笔记，开始归纳主要发现和方法论趋势。在这个阶段，你可以用 AI 辅助整理思路：

“我阅读了 20 篇关于算法歧视的实证研究，以下是我的笔记摘要。请帮我识别这些研究在方法论上的共同点和差异，以及主要发现的共识和争议。”

AI 给出了一个初步的综合，你在此基础上修改和补充，加入你自己的分析和判断。

### **第七步：撰写报告（迭代润色）**

你先手写一个粗略的提纲，然后逐节展开写作。写完初稿后，可以用 AI 帮助检查语言流畅度、识别论述空白。

但最终的判断——这篇综述是否准确反映了文献的实际状况——只有你自己能做出，因为只有你真正读过那些原始论文。

### **第八步：保留记录（版本记录）**

整个过程中，你保留了：– 检索记录（日期、数据库、检索词、结果数量）– 原始文献列表（200 篇的题目、摘要、来源）– AI 对话记录（每次使用 AI 的输入和输出）– 阅读笔记（20 篇精读论文的详细笔记）– 写作版本（综述报告的多份修订版本）

当导师问你任何问题，你都可以追溯到原始证据。

## **4.6.3 6.3 两种做法的对比**

两种做法的时间投入差别很大——第二种可能需要两周，第一种可能只需要两小时。但产出的质量完全不同。

更重要的是，第二种做法在过程中建立了真正的理解。你读完那 20 篇论文后，你对这个领域有了真正的认识，能够参与专业讨论，能够识别新研究的价值和问题。第一种做法什么都没有留下——既没有知识的积累，也没有可追溯的记录。

AI 在第二种做法中确实发挥了作用：它帮助你进行了初步分类，节省了大量筛选时间；它帮助你综合笔记，加速了写作过程。但 AI 的角色是明确的、有限的、受控的。它是研究系统中的一个组件，而不是整个系统的替代品。

## **4.7 七、写在最后**

让我回到本章开始时那个 AI 工作坊的场景。

那位主讲人教授的提示词技巧，严格来说并没有错。格式约束、角色设定、任务分解——这些确实是有用的技巧。问题在于，他把这些技巧包装成了某种“终极解决方案”，暗示掌握了这些提示词就能解决学术研究的核心难题。

但学术研究的核心难题——提出有价值的问题、设计可靠的方法、做出准确的判断、构建有说服力的论

证——不是任何提示词能够解决的。这些能力需要长期积累，需要深入阅读，需要反复实践，需要失败和纠错。提示词可以在这个过程中提供一些辅助，但它不是捷径，因为根本就没有捷径。

这就是为什么我说“提示词不是方法论”。方法论是关于“如何做好研究”的系统性思考，它涉及研究设计、证据标准、推理规则、质量控制。提示词只是与 AI 交互的界面，它是技术层面的，而不是方法论层面的。把提示词当作方法论来学习，就像把“如何握笔”当作“如何写好文章”来学习——不是说握笔不重要，但它解决不了写作的真正难题。

我希望这一章能够帮助读者建立一个更健康的与 AI 的关系。这个关系的核心是：**AI 是工具，不是导师；是助手，不是替代；是流程中的一个环节，不是整个流程。**

理解了这一点，你就会知道应该把精力放在哪里。不是去收集更多的提示词模板，而是去培养自己的研究能力。不是去追求“一键生成”的幻觉，而是去构建可靠的工作系统。不是去问“有没有更好的提示词”，而是去问“我的研究流程哪里可以改进”。

提示词可以优化，但方法论需要建构。前者是技巧，后者是能力。这本书的目的，正是帮助你从技巧走向能力。

## 5 第 4 章 信息压缩与文献整理

### 5.1 引言：从信息过载到结构化管理

学术研究者面临的核心挑战之一是信息过载。一个活跃的研究领域每年可能产出数千篇论文，而研究者的阅读时间是有限的。传统的文献整理方法——逐篇阅读、手工分类、人工综合——在信息爆炸的时代显得力不从心。大语言模型的出现为这一困境提供了新的可能性：它们能够快速处理大量文本，提取关键信息，生成结构化的摘要和分类。

然而，这种可能性伴随着显著的风险。模型可能遗漏重要文献，可能错误归纳论点，可能生成不存在的引用。如果研究者不加辨别地接受 AI 的输出，信息压缩就会变成信息扭曲。本章的目标是探讨如何在文献整理工作中有效利用 AI 的信息压缩能力，同时建立必要的质量保障机制。

本章将依次讨论三个核心议题：文献筛选与主题聚类的方法，长上下文模型的正确使用方式，以及可信综述生成的验证策略。贯穿这些讨论的核心原则是：AI 的输出应被视为“索引”而非“结论”，是研究过程的起点而非终点。

### 5.2 一、文献筛选与主题聚类

#### 5.2.1 1.1 文献筛选的两阶段模型

文献筛选是任何研究项目的基础工作。传统的筛选流程通常包括：确定检索策略、执行数据库检索、根据题目和摘要进行初筛、根据全文进行精筛。这个流程的瓶颈在于初筛阶段——面对数百甚至数千条检索结果，研究者需要逐条判断相关性，这是一项耗时且认知负担沉重的工作。

AI 辅助可以显著提高初筛阶段的效率，但前提是研究者理解这种辅助的性质和边界。我建议采用“两阶段模型”来组织 AI 辅助的文献筛选工作。

第一阶段是 AI 辅助的粗筛。在这个阶段，研究者将检索结果（通常是题目和摘要的列表）提交给模型，要求模型根据预设的纳入和排除标准进行初步分类。模型的任务是识别“明显相关”“明显不相关”和“需要进一步判断”三类文献。这个阶段的目标不是获得最终的筛选结果，而是快速缩小需要人工审阅的范围。

第二阶段是人工复核与精筛。研究者对 AI 标记为“明显相关”和“需要进一步判断”的文献进行人工审阅，做出最终的纳入决策。同时，研究者应当抽样检查 AI 标记为“明显不相关”的文献，评估 AI 的假阴性率（即被错误排除的相关文献比例）。如果假阴性率过高，需要调整第一阶段的指令或标准。

这个两阶段模型的核心逻辑是：AI 负责处理“容易”的决策（明显相关或明显不相关的文献），人类负责处理“困难”的决策（边界情况和最终判断）。这种分工既利用了 AI 的处理速度，又保留了人类的判断权威。

#### 5.2.2 1.2 设计有效的筛选指令

AI 辅助筛选的效果高度依赖于指令的质量。一个有效的筛选指令应当包含以下要素。

首先是明确的研究问题陈述。研究者需要清晰地告诉模型，这次文献检索要回答什么问题。模糊的问题陈述会导致模糊的筛选结果。例如，“关于气候变化的研究”是一个过于宽泛的陈述，而“关于碳税政策对企业减排行为影响的实证研究”则提供了明确的边界。

其次是具体的纳入标准。纳入标准应当是可操作的、可判断的。例如：“纳入标准：(1) 研究对象为企业或行业层面的减排行为；(2) 研究方法为实证分析（包括定量和定性）；(3) 研究涉及碳税或碳定价政策；(4) 发表时间为 2015 年至今。”这些标准使得模型能够对每一篇文献做出相对客观的判断。

第三是明确的排除标准。排除标准帮助模型识别那些表面相关但实际不符合需求的文献。例如：“排除标准：(1) 纯理论或模拟研究，无实证数据；(2) 研究对象为个人消费者行为而非企业行为；(3) 仅讨论碳交易而不涉及碳税；(4) 会议摘要、书评、社论等非研究性文献。”

第四是输出格式的规定。研究者应当明确告诉模型如何呈现筛选结果。例如：“请将每篇文献分类为‘纳入’‘排除’或‘待定’，并简要说明分类理由（一句话）。”结构化的输出便于后续的人工复核和记录。

### 5.2.3 1.3 主题聚类的策略

主题聚类是文献整理的另一项核心任务。当研究者面对一个新的研究领域时，往往需要首先了解这个领域的主要研究主题、核心争论和知识结构。传统的做法是通过广泛阅读逐步建立这种理解，但这需要大量时间。AI 可以帮助研究者快速获得一个初步的领域地图。

有效的主题聚类需要遵循几个原则。

第一个原则是层次化聚类。不要试图一次性获得一个完美的分类体系，而是采用从粗到细的迭代策略。第一轮聚类可以识别 3–5 个大的主题领域；第二轮在每个大主题下进一步细分子主题；第三轮识别子主题之间的交叉和联系。这种层次化的方法既便于理解，也便于发现聚类中的问题。

第二个原则是多维度聚类。同一批文献可以从不同维度进行分类。例如，按研究主题分类、按研究方法分类、按研究对象分类、按理论框架分类。不同的分类维度揭示领域的不同面向。研究者应当根据自己的研究需求选择最相关的分类维度，或者综合使用多个维度。

第三个原则是保留边界案例。在聚类过程中，总会遇到难以归类的文献——它们可能跨越多个主题，或者不完全符合任何现有类别。这些边界案例往往具有特殊的价值：它们可能代表新兴的研究方向，或者揭示现有分类体系的局限。研究者不应强行将这些文献塞入某个类别，而应单独标记，作为进一步探索的线索。

第四个原则是验证聚类结果。AI 生成的聚类结果需要人工验证。验证的方法包括：从每个聚类中随机抽取几篇文献，检查它们是否真的属于同一主题；检查聚类的标签是否准确反映了聚类内容；寻找是否有明显的误分类。如果发现系统性的问题，需要调整聚类指令并重新执行。

### 5.2.4 1.4 一个实践案例

为了说明上述原则的应用，我将描述一个具体的文献筛选与聚类案例。

假设研究者正在开展一项关于“社交媒体对学术传播影响”的研究。初步的数据库检索返回了 350 篇相关文献的题目和摘要。研究者的任务是从中筛选出与研究问题直接相关的文献，并对这些文献进行主题分类。

第一步，研究者设计了筛选指令。纳入标准包括：实证研究社交媒体（如 Twitter/X、ResearchGate、Academia.edu）对学术论文传播的影响；研究涉及可测量的传播指标（如引用、阅读量、讨论度）；研究对象为学术论文或学术成果。排除标准包括：纯描述性的社交媒体使用调查；仅讨论社交媒体对教学的影响；技术性的平台分析而非传播效果研究；非英文文献。

第二步，研究者将 350 篇文献的题目和摘要提交给模型，要求模型按照上述标准进行分类。模型返回了以下结果：92 篇标记为“纳入”，198 篇标记为“排除”，60 篇标记为“待定”。

第三步，研究者对结果进行人工复核。首先，研究者审阅了 60 篇“待定”文献，最终纳入其中的 35 篇，排除 25 篇。然后，研究者从 198 篇“排除”文献中随机抽取 20 篇进行检查，发现其中 3 篇实际上符合纳入标准（假阴性率约 15%）。基于这个发现，研究者决定扩大抽查范围，又检查了 30 篇“排除”文献，额外发现了 4 篇应当纳入的文献。最终的纳入文献数量为 134 篇。

第四步，研究者对 134 篇纳入文献进行主题聚类。第一轮聚类识别出四个大主题：（1）社交媒体与引用影响；（2）社交媒体与公众传播；（3）学术社交网络平台研究；（4）社交媒体使用行为研究。第二轮聚类在每个大主题下进一步细分。例如，“社交媒体与引用影响”下细分为“Twitter 讨论与引用相关性”“Altmetrics 指标研究”“因果效应估计”三个子主题。

第五步，研究者验证聚类结果。从每个子主题中抽取 3 篇文献进行审阅，确认分类的准确性。在验证过程中发现，“Altmetrics 指标研究”这个子主题过于宽泛，包含了指标本身的研究和指标应用的研究两类不同性质的文献，需要进一步拆分。

通过这个案例可以看到，AI 在筛选和聚类过程中发挥了重要的辅助作用，显著减少了人工处理的工作量。但每个关键节点都有人工的参与和验证，确保了最终结果的可靠性。

## 5.3 二、长上下文模型的正确用法

### 5.3.1 2.1 长上下文能力的本质与局限

近年来，大语言模型的上下文窗口经历了显著扩展。早期的模型只能处理几千个 token，而最新的模型已经能够处理数十万甚至上百万个 token。这意味着研究者理论上可以将几十篇论文的全文一次性输入模型，要求模型进行综合分析。

然而，“能够处理”不等于“能够有效处理”。研究表明，即使是长上下文模型，其在不同位置的信息利用效率也存在显著差异。一般而言，模型对上下文开头和结尾的信息利用较好，而对中间部分的信息利用较差——这被称为“中间丢失”现象。此外，当上下文过长时，模型生成的回答往往变得更加泛化和模糊，丢失了对具体细节的把握。

这些发现对学术研究有重要启示。将大量论文一次性输入模型，期望获得一个全面准确的综合分析，这种期望是不现实的。更有效的策略是理解长上下文的局限，设计相应的使用方法。

### 5.3.2 2.2 分层处理策略

面对长上下文的局限，我建议采用分层处理策略。这个策略的核心思想是：不要试图让模型一次完成所有工作，而是将任务分解为多个层次，每个层次处理适量的信息。

第一层是单篇论文的信息提取。对于每一篇需要纳入分析的论文，首先单独提取关键信息。提取的内容可能包括：研究问题、理论框架、研究方法、核心发现、主要结论、局限性。这个层次的任务相对简单，模型通常能够较好地完成。研究者可以设计一个标准化的提取模板，确保从每篇论文中获取可比较的信息。

第二层是小组论文的比较分析。将具有相似主题或方法的 3-5 篇论文组成一个小组，要求模型对这个小组进行比较分析。比较的维度可能包括：研究发现的一致性与差异、方法论的异同、理论框架的关系。这个层次的任务开始涉及综合和推理，模型的表现会有更大的不确定性，需要研究者的仔细审核。

第三层是跨组的综合归纳。在完成所有小组的分析之后，将各组的分析结果作为输入，要求模型进行更高层次的综合。这个层次的输入是已经经过压缩和结构化的信息，而非原始的论文全文，因此更适合模型处理。

这种分层策略的优势在于：每一层的任务都保持在模型能够有效处理的范围内；每一层都有明确的输出，便于人工审核和质量控制；错误可以在较早的层次被发现和纠正，而不会传递到最终输出。

### 5.3.3 2.3 输入质量的重要性

长上下文模型的输出质量高度依赖于输入的质量。“垃圾进，垃圾出”的原则在这里尤其适用。研究者在准备输入材料时，应当注意以下几点。

首先是格式的一致性。如果输入的材料格式混乱——有的是纯文本，有的是 PDF 提取的乱码，有的包含大量表格和图片描述——模型的处理效果会大打折扣。研究者应当在输入之前对材料进行预处理，确保格式的统一和清洁。

其次是信息的相关性。不是论文的所有部分都与研究者的分析需求相关。如果研究者只关心研究方法和发现，那么将论文的致谢、参考文献列表、补充材料等全部输入模型，不仅浪费了上下文空间，还可能引入噪音。研究者应当有选择地提取和输入最相关的部分。

第三是结构的清晰性。在输入多篇论文时，应当使用清晰的分隔符和标识，让模型能够区分不同论文的内容。例如，可以在每篇论文的开头添加标识：“[论文 1] 作者：xxx，标题：xxx，年份：xxx”。这种结构化的输入有助于模型准确地引用和归因。

### 5.3.4 2.4 输出设计与质量控制

除了优化输入，研究者还应当精心设计期望的输出格式，并建立相应的质量控制机制。

在输出设计方面，研究者应当明确告诉模型输出的结构和详细程度。例如：“请按以下格式输出：(1) 主要发现综述 (200 字以内)；(2) 研究方法比较表格；(3) 发现一致性分析；(4) 发现差异分析；(5) 研究空白识别。”结构化的输出要求不仅便于后续使用，也使得质量检查更加系统化。

在质量控制方面，最重要的原则是可追溯性。模型的每一个陈述都应当能够追溯到具体的原始来源。研究者可以要求模型在输出中标注来源，例如：“Smith 等 (2020) 发现社交媒体讨论与引用存在正相关 [论

文 3]”。然后研究者需要回到原始论文验证这个陈述是否准确。

另一个重要的质量控制方法是交叉验证。对于同一批论文，可以从不同的角度或使用不同的指令让模型进行分析，然后比较结果的一致性。如果两次分析得出截然不同的结论，说明至少有一次分析存在问题，需要人工介入检查。

### 5.3.5 2.5 一个错误使用的案例

为了说明不当使用长上下文模型的风险，我将描述一个反面案例。

一位研究生正在撰写一篇关于数字鸿沟的文献综述。他收集了 45 篇相关论文的 PDF 文件，使用工具将这些 PDF 转换为文本，然后一次性将所有文本（约 50 万字）输入一个长上下文模型，要求模型“写一篇全面的文献综述，总结这 45 篇论文的主要发现和研究趋势”。

模型生成了一篇约 3000 字的综述，结构完整，语言流畅。这位研究生非常满意，稍作修改后就准备使用。但他的导师要求他核对其中几个关键陈述的来源。

核对的结果令人担忧。综述中的一个陈述是：“Chen 等（2019）的元分析发现，数字鸿沟对教育成就的影响效应量为  $d=0.42$ 。”但当研究生查找这篇论文时，发现 Chen 等（2019）的研究根本不是元分析，而是一项单一的调查研究，也没有报告过  $d=0.42$  这个效应量。另一个陈述是：“近年来的研究趋势从关注接入差距转向关注使用差距和技能差距。”这个陈述本身可能是正确的，但模型没有提供任何具体证据，研究生也无法追溯这个“趋势”判断的来源。

这个案例说明了几个问题。第一，将大量未经预处理的材料一次性输入模型，模型无法有效利用所有信息。第二，期望模型一次性完成复杂的综合任务，超出了模型的可靠能力范围。第三，没有建立验证机制，导致错误直到被要求核对时才被发现。第四，模型生成的流畅文本给研究者造成了虚假的信心，掩盖了内容上的问题。

正确的做法应该是采用前文描述的分层处理策略：先对每篇论文单独提取信息，然后分组比较，最后综合归纳，每一步都进行验证。

## 5.4 三、可信综述生成：引用与验证

### 5.4.1 3.1 为什么综述生成是高风险任务

文献综述是学术写作中最常见也最容易被 AI 辅助的任务之一。但它同时也是风险最高的任务之一。这种高风险源于几个因素。

第一，综述涉及对多个来源的准确归纳。模型不仅需要理解每一篇论文的内容，还需要准确地表述每篇论文说了什么、没说什么。任何一个错误归纳都可能误导读者，损害综述的可信度。

第二，综述需要准确的引用。学术写作的核心规范之一是“言必有据”——每一个关于先前研究的陈述都应当有明确的来源。模型生成虚假引用的问题在学术界已经广为人知。即使引用的论文确实存在，模型对其内容的概括也可能不准确。

第三，综述涉及判断和评价。好的综述不仅仅是论文的罗列，还需要对研究进行评价、识别研究空白、提出未来方向。这些任务需要深入的领域知识和批判性思维，超出了当前模型的可靠能力范围。

第四，综述的错误难以被非专家发现。一篇语言流畅、结构合理的综述，即使内容有问题，读者也很难察觉。尤其是当读者没有阅读过原始论文时，他们无法判断综述的归纳是否准确。

基于这些风险，我建议将综述生成视为“高风险任务”，采用最严格的验证机制。

### 5.4.2 3.2 AI 在综述生成中的适当角色

尽管风险很高，AI 在综述生成中仍然可以发挥有价值的辅助作用，只要研究者正确定位 AI 的角色。

AI 适合承担的任务包括：生成初步的组织框架、识别可能的主题分类、对单篇论文进行摘要、提示可能被遗漏的角度。这些任务的共同特点是：它们是“启发性”的而非“结论性”的——AI 的输出是供研究者参考和修改的草稿，而非最终产品。

AI 不适合承担的任务包括：对论文观点的权威性概括、对研究质量的评价、对研究领域的趋势判断、任何需要作为最终产品使用的内容。这些任务需要研究者自己完成，或者在 AI 辅助的基础上进行充分的人工审核和修改。



一个有用的思维框架是区分“生成”和“使用”两个阶段。在生成阶段，研究者可以自由地使用 AI 来探索想法、生成草稿、获取灵感。在使用阶段——也就是将内容放入最终的学术产品中——每一个陈述都必须经过验证，确保其准确性和可追溯性。

### 5.4.3 3.3 引用验证的系统方法

引用验证是综述生成中最关键的质量控制环节。我建议采用系统化的验证方法。

第一步是列出所有引用。将 AI 生成的综述中所有的文献引用提取出来，形成一个完整的列表。每个引用应当记录：作者、年份、被引用的具体观点或发现。

第二步是验证引用的存在性。确认每一篇被引用的文献确实存在。检查作者姓名、发表年份、期刊或会议名称是否正确。使用 Google Scholar、Web of Science 或其他数据库进行验证。如果发现一篇文献不存在或信息有误，这是一个明确的红旗，需要删除该引用并检查 AI 输出中的其他引用。

第三步是验证引用的准确性。这是最耗时但也是最重要的步骤。对于每一个引用，回到原始论文，确认综述中的概括是否准确反映了原文的观点。常见的问题包括：夸大了原文的发现、忽略了原文的限定条件、将原文的假设表述为结论、混淆了不同论文的内容。

第四步是标记验证状态。为每个引用标记验证状态：已验证、待验证、存疑、已删除。这个标记帮助研究者追踪验证进度，确保没有遗漏。

第五步是迭代修正。根据验证结果修正综述内容。对于发现的错误，不仅要修正具体的陈述，还要反思错误的模式——是某一类论文的概括容易出错，还是某一种陈述类型容易出错？这种反思有助于改进后续的工作流程。

### 5.4.4 3.4 建立可追溯的证据链

可信的综述不仅需要引用准确，还需要建立清晰的证据链，使读者能够追溯任何陈述的来源。

证据链的建立始于数据管理。研究者应当建立一个结构化的文献数据库，记录每篇论文的基本信息、核心内容摘要、以及在综述中如何被使用。文献管理软件如 Zotero、EndNote、Mendeley 可以支持这一工作，但研究者需要超越简单的书目管理，为每篇文献添加结构化的笔记和标签。

证据链的维护贯穿写作过程。在综述写作的每一个阶段，研究者都应当能够回答：这个陈述的依据是什么？来自哪篇文献的哪个部分？如果无法回答这些问题，说明证据链存在断裂，需要补充或修正。

证据链的最终呈现体现在综述文本中。读者应当能够通过引用信息找到原始来源，并验证综述中的陈述。这要求引用必须具体和准确——引用到具体的页码或章节，而非笼统地引用整篇论文。

### 5.4.5 3.5 AI 辅助综述的披露与伦理

使用 AI 辅助生成学术综述涉及伦理问题，研究者有责任进行适当的披露。

不同的学术机构和期刊对 AI 使用的披露要求不同。有些要求详细说明 AI 在写作中的角色，有些只要求声明是否使用了 AI，有些尚未制定明确的政策。研究者应当了解并遵守相关的规定。

即使没有明确的披露要求，透明度也是学术诚信的基本原则。我建议在使用 AI 辅助综述生成时，至少在方法部分说明：使用了哪些 AI 工具、AI 在哪些环节发挥了作用、研究者采取了哪些验证措施。这种披露不会减损研究的价值，反而展示了研究者的方法论自觉。

需要强调的是，披露 AI 的使用并不能免除研究者对最终内容的责任。无论 AI 在生成过程中扮演了多大的角色，发表的内容归研究者所有，研究者对其准确性和诚信性负有完全的责任。AI 是工具，而使用工具的方式——以及对工具输出的把关——是研究者的选择和责任。

## 5.5 四、从工具到能力：信息素养的新维度

### 5.5.1 4.1 信息压缩作为研究者的核心能力

本章的讨论可能给读者一个印象：AI 正在接管文献整理的工作。但我想在结束时强调一个相反的观点：信息压缩是研究者的核心能力，AI 的参与不应削弱这一能力的培养。

信息压缩能力包括几个层面。第一个层面是快速识别信息价值的能力——看一篇论文的摘要，就能判断它与研究问题的相关程度。第二个层面是提取核心论点的能力——阅读一篇论文，能够准确把握其主要贡献和局限。第三个层面是综合多个来源的能力——将多篇论文的发现整合为连贯的知识图景。第四个层面是识别知识空白的能力——看到现有文献的整体轮廓，能够发现尚未被研究的问题。

这些能力需要通过实践来培养。阅读大量论文、写作多篇综述、经历导师的反馈和修改——这个过程不能被跳过或压缩。AI 可以帮助提高效率，但不能替代学习过程本身。

### 5.5.2 4.2 人机协作的最优配置

对于研究者而言，关键问题是：如何配置人类和 AI 在文献整理工作中的角色，以实现最优的结果？

我建议的配置原则是：AI 负责规模化处理和格式化任务，人类负责判断和验证任务。

在文献筛选中，AI 可以处理数百篇文献的初步分类，人类负责边界情况的判断和分类准确性的验证。在主题聚类中，AI 可以提供初步的聚类方案，人类负责评估聚类的合理性并进行调整。在信息提取中，AI 可以从论文中提取结构化信息，人类负责检查提取的准确性。在综述写作中，AI 可以协助生成草稿和组织框架，人类负责内容的验证、判断和最终表述。

这种配置的核心逻辑是：利用 AI 的速度优势处理那些规则明确、可批量执行的任务，同时保留人类对关键节点的控制权。人类的时间和认知资源应当集中在那些真正需要专业判断的环节。

### 5.5.3 4.3 未来研究者的信息素养

AI 工具的普及正在改变研究者所需的信息素养。传统的信息素养强调检索技能——如何使用数据库、如何构建检索策略、如何管理文献。这些技能仍然重要，但不再足够。

未来的研究者需要掌握新的信息素养。第一是 AI 素养——理解 AI 工具的能力和局限，知道如何有效地使用它们，也知道在什么情况下不应该使用它们。第二是验证素养——能够系统地检查 AI 输出的准确性，建立可追溯的证据链，识别和纠正错误。第三是 workflow 设计素养——能够设计人机协作的工作流程，优化任务在人类和 AI 之间的分配。第四是元认知素养——保持对自己认知过程的反思，避免因过度依赖 AI 而导致的能力退化。

这些素养不会自动获得，需要有意识地培养。研究者应当在实践中不断反思自己使用 AI 的方式，评估效果，调整策略。学术机构和导师也应当为研究生提供相关的培训和指导。

## 5.6 结语

本章讨论了 AI 辅助文献整理的方法和原则。核心论点可以总结为：AI 能够显著提高信息压缩的效率，但这种效率提升必须以可靠性为前提。研究者应当把 AI 的输出视为“索引”而非“结论”，是需要验证的起点而非可以信任的终点。

在文献筛选中，两阶段模型——AI 辅助粗筛加人工复核精筛——能够在效率和准确性之间取得平衡。在使用长上下文模型时，分层处理策略能够避免信息过载导致的质量下降。在综述生成中，严格的引用验证和证据链管理是确保可信度的必要措施。

贯穿这些讨论的，是对研究者主体性的强调。AI 改变了文献整理的方式，但没有改变文献整理的目的——那就是建立研究者对一个领域的深入理解。这种理解不能被外包给机器，只能通过研究者自己的阅读、思考和综合来建立。AI 是这个过程中的有力工具，但工具的价值最终取决于使用工具的人。

## 6 第 5 章 结构化表达与写作

AI 能快速生成提纲、段落与结构，这在写作初期非常有用。你可以用它来整理研究框架、提出章节结构、梳理论证顺序。但要记住：结构不是思想，结构只是容器，关键是你要把真正的论证放进去。

“学术语言”与“AI 语言”之间的差别常常被忽视。AI 写出来的文字通常流畅、完整，但容易缺乏学术写作所需的精确性与责任感。它倾向于“把话说满”，而研究写作更强调“留出不确定性”。因此，AI 生成文本需要二次加工：删去过度自信的表达，补上证据与限定条件。

在翻译与润色上，AI 的优势是速度，但风险是术语与语境的偏差。最好的策略是：让 AI 做“第一遍粗修”，再由研究者做“关键点审校”。尤其是方法与结果部分，不能完全依赖 AI 完成。

## 7 第 6 章 代码与计算能力

AI 对代码的帮助不在于“自动生成”，而在于“降低门槛”。它可以帮助你模糊想法转成可运行的脚本，减少重复劳动，并在遇到错误时快速定位问题。但这并不意味着你可以不理解代码。任何研究级分析都要求你能解释每一步处理逻辑。

在数据清洗、格式转换、批量处理等任务上，AI 的效率优势非常明显。它能快速给出脚本框架和可复用函数，适合用作“草稿生成器”。你应当把它当作代码搭子：让它产出、让你审核、共同迭代。

在统计分析与可视化上，AI 可以协助你构建模型、输出图表，但不能替代对模型假设的理解。模型选择、变量定义、结果解释都属于研究者的责任。AI 提供的是加速，而不是合法性。

## 8 第 7 章 知识管理与协作

AI 的最大价值之一是“对话式启发”，但对话如果不被整理，就会迅速消失。研究需要记录、归档与版本管理。你需要把 AI 对话转成可检索的研究材料，而不是散落的聊天记录。

一个可用的流程是：对话 → 摘要 → 标签 → 归档。每次关键对话都应输出结构化总结，并注明时间、模型、提示词与用途。这些记录构成研究的“隐形材料”，决定了你能否复现自己的思路。

在团队协作中，AI 既能提升效率，也会模糊责任边界。谁写的、谁验证的、谁承担错误？这些问题必须在协作中明确。开源和透明不只是技术选择，也是团队协作的伦理底线。

## 9 第 8 章 选题与研究问题

选题阶段是 AI 最容易“帮倒忙”的环节。它能快速生成许多漂亮的问题，但这些问题往往缺乏可检验性、现实可行性或理论价值。研究者必须先明确研究问题的“可研究性”，再使用 AI 辅助拆解。

一个有效的方法是先由人写出核心问题，再让 AI 做“多角度压力测试”：是否存在可用数据？是否已有大量研究？是否存在明确的识别路径？AI 擅长从多个角度给出提醒，但这些提醒必须由研究者来做最终判断。

最常见的风险是“问题被做空”：AI 倾向于把复杂问题简化为泛化叙述，导致研究失去锋利度。研究者要主动保持问题的边界感，避免被 AI“优化成毫无棱角的宏大命题”。

## 10 第 9 章 文献与理论构建

AI 可以帮你搭建“文献地图”，但搭建“理论链条”仍然需要研究者的判断力。文献地图强调覆盖面，理论链条强调逻辑性。二者不是同一件事。

在文献整理阶段，AI 适合做主题聚合与脉络描述：哪些研究关注同一问题、哪些方法常被使用、哪些争议存在。但理论构建需要你明确变量关系与因果机制，AI 只能辅助解释，不能替你承担理论责任。

所谓“AI 综述陷阱”是指：输出看起来完整，但引用无法核对，或者概念混杂不清。避免陷阱的办法是把 AI 综述当成“初稿目录”，逐条回到原文校验，并用“证据链”替换“叙述链”。

## 11 第 10 章 数据获取与构造

数据获取是 AI 加速最明显的环节之一。无论是公开数据、爬虫还是 API 接口，AI 都能帮助你快速写出脚本并完成批量抓取。但“获取速度”不等于“数据质量”，任何数据都需要清晰的采集记录与合法性说明。

AI 生成数据是更具争议的方向。它可以用于模拟、训练或思维实验，但不能轻易替代真实样本。研究者必须区分“生成数据用于方法测试”和“生成数据用于经验结论”这两种完全不同的用途。

“硅样本”的方法论争议在于：AI 是否能代表人类行为？如果 AI 是研究对象，它本身就不是“人”。使用硅样本必须明确其理论定位，否则会把“模型输出”误当成“社会事实”。



## 12 第 11 章 数据清洗与分析

数据清洗是科研中最耗时也最容易被忽略的环节。AI 的优势在于快速生成清洗脚本和规则，尤其适用于文本数据的结构化处理。但清洗规则背后往往包含方法论选择，这些选择必须透明化、可解释、可复现。

在统计分析阶段，AI 可以帮助搭建模型、生成图表、解释结果，但研究者必须对模型假设负责。AI 擅长“讲故事”，但不擅长“守住边界”。如果你让 AI 解释结果，它可能会给出看似合理但并不严谨的因果叙述。

因此，AI 的角色应该是“分析助手”，而不是“结论生成器”。任何结论性表述必须回到数据与方法本身，这是学术研究的底线。

## 13 第 12 章 写作、投稿与传播

AI 最受欢迎的应用场景是写作。你可以用它生成初稿、润色语言、调整结构，但这并不意味着它能替你“完成论文”。论文的核心价值来自研究设计与证据，而不是表达方式。

在投稿流程中，AI 可以帮助你整理摘要、润色投稿信、模拟审稿人视角。但“反 AI 检测”不应该成为研究者的目标。真正合理的策略是：确保内容真实、证据充分、逻辑清晰。所谓“AI 味”，往往来自缺乏具体细节与可验证信息，而不是语言风格本身。

在答辩与传播阶段，AI 适合帮助你做摘要、演讲稿与受众调整，但关键观点必须是你自己的。AI 可以把话说漂亮，但不能替你承担学术立场。

## 14 第 13 章 RA Level：工具层

在工具层，AI 等同于一个高效率的研究助理。它能完成大量重复性工作：整理数据、生成初稿、清洗文本、批量翻译。这个层级的核心价值是节省时间和成本。

但工具层的风险在于“过度依赖”。当 AI 替代了研究者的基础劳动，研究者也可能丧失对材料的直觉理解。你必须确保自己仍然掌握数据细节和研究逻辑，否则 AI 的效率会把你带向“看似完成但无法解释”的境地。

最重要的问题是：谁在控制流程？如果 AI 的输出驱动了你的研究方向，那么你已经从“使用工具”变成“被工具牵引”。工具层的原则是：AI 做脏活累活，人保留判断权。

## 15 第 14 章 Supervisor Level：认知协作层

在认知协作层，AI 不只是执行者，而是“对话式导师”。它能帮助你提出假设、模拟审稿人、补足背景知识，甚至推动你跨学科思考。这一层是 AI 最有创造性的应用。

但同样，风险也在于“依赖与懒惰”。当你习惯用 AI 生成思路，可能会丧失独立构建问题的能力。AI 会不断给出“合理建议”，但合理并不等于有价值。研究者必须保持自己的问题意识与判断标准。

认知协作层的关键是：让 AI 成为“思维刺激器”，而不是“思维替代品”。你可以借助 AI 扩展视野，但不能放弃自己的判断。

## 16 第 15 章 Domain Expert Level: 推理与建模层

在推理与建模层，AI 能够模拟“领域专家”的思维方式，帮助你理解模型、构建算法或补齐技术短板。对跨学科研究者而言，这一层极具价值，因为它能缩短学习曲线。

但必须明确：推理不等于理论。AI 可以生成“看似合理”的模型，却不一定满足学科内部的规范与逻辑要求。理论构建需要领域知识、文献脉络与方法论约束，而这些不是 AI 能自动承担的。

这一层的正确使用方式是：让 AI 提供“草稿与解释”，由研究者完成“理论合法性与方法论判断”。领域知识的不可替代性，恰恰是学术研究者的核心价值。

# 17 第 16 章 Agent Level: AI 作为行动者

## 17.1 引言：当 AI 不再只是工具

在前面几章的讨论中，AI 始终扮演着“工具”的角色——它帮助研究者处理文献、分析数据、润色文本，但研究的主体始终是人类，研究的对象也是人类社会。然而，随着大语言模型能力的提升和应用场景的扩展，一个更深层的问题开始浮现：AI 是否正在成为一种新型的“行动者”（agent），不仅参与研究过程，还可能成为研究对象本身？

这个问题并非纯粹的哲学思辨，而是具有实际的方法论意义。当研究者使用 AI 模拟人类行为时，他们在研究什么？当 AI 被部署在社会系统中与人类互动时，这种互动应该如何被理论化？当“硅样本”（silicon samples）——由 AI 生成的模拟人类反应的数据——被用于社会科学研究时，其效度和适用范围如何界定？

本章将探讨 AI 作为行动者的多重维度。第一节讨论 AI 进入社会科学本体论所带来的理论挑战。第二节分析使用 AI 模拟社会和生成虚拟样本的方法论问题。第三节探讨“行动者”概念在 AI 时代的扩展与重构。第四节提出研究者在面对这些新问题时应当采取的立场和策略。

## 17.2 一、AI 进入社会科学的本体论

### 17.2.1 1.1 社会科学的基本预设

传统社会科学建立在一个基本预设之上：社会是由具有意向性（intentionality）的人类行动者构成的。人类行动者能够赋予行动以意义，能够基于信念和欲望做出选择，能够对自己的行为进行反思和调整。社会科学的任务，无论是解释因果机制还是理解意义结构，都以人类行动者为核心。

这个预设从未受到根本性挑战。虽然社会科学家研究过各种非人类因素——技术、制度、文化符号——但这些因素始终被理解为人行动的语境或产物，而非独立的行动者。布鲁诺·拉图尔（Bruno Latour）的行动者网络理论（Actor–Network Theory）曾试图赋予非人类实体以行动者地位，但这种理论创新更多是一种分析策略，而非对现实本体论的重新定义。

AI 的出现正在动摇这个基本预设。大语言模型展现出令人惊讶的语言能力：它们能够进行对话、回答问题、表达观点、甚至表现出某种程度的“个性”。当用户与 ChatGPT 交谈时，这种互动在现象学层面与人际对话具有相似性。当 AI 被部署在客服系统、社交媒体或在线社区中时，它们的“行为”产生了真实的社会后果——影响人们的决策、改变互动模式、塑造信息环境。

### 17.2.2 1.2 三种本体论立场

面对 AI 的行动者地位问题，学术界存在三种主要立场。

第一种立场是“工具主义”（instrumentalism）。这种立场认为，无论 AI 的表现多么类似人类，它本质上仍然是工具。AI 没有真正的意识、意向性或主体性，它的所有“行为”都是算法运行的结果。将 AI 视为行动者是一种范畴错误，就像将计算器视为“思考者”一样。社会科学应当研究的是人类如何使用 AI、人类与 AI 的互动如何影响社会，而不是把 AI 本身当作社会行动者。

第二种立场是“功能主义”（functionalism）。这种立场认为，行动者地位应当根据功能而非本质来定义。如果一个实体能够在社会系统中发挥类似人类行动者的功能——接收信息、做出反应、影响其他行动者——那么它就应当被视为行动者，无论其内部机制是什么。这种立场不需要解决 AI 是否具有“真正”意识的哲学难题，只需要承认 AI 在社会互动中的功能性角色。

第三种立场是“关系主义”（relationalism）。这种立场认为，行动者地位是在关系中构成的，而非实体固有的属性。当人类将 AI 当作对话伙伴、当社会系统将 AI 的输出当作有意义的信号、当制度将 AI 的决策当作需要问责的行为时，AI 就在这些关系中获得了某种程度的行动者地位。行动者地位是一个程度问题，而非非此即彼的二元划分。

### 17.2.3 1.3 对社会科学方法的影响

这些本体论立场的分歧不仅是哲学争论，还直接影响到研究方法的选择。

如果采取工具主义立场，研究者将继续使用传统的社会科学方法，只是把 AI 视为一种新型的技术变量。研究问题可能是：AI 工具的采用如何影响劳动市场？人们对 AI 生成内容的信任程度如何？AI 辅助决策系统是否存在歧视？这些问题将 AI 置于研究的背景中，而非中心位置。

如果采取功能主义立场，研究者可能需要发展新的概念框架来描述 AI 的“行为”。例如，AI 的输出是否可以被理解成一种“言语行为”（speech act）？AI 在决策系统中的角色是否可以用“代理”（agency）概念来分析？这种立场要求社会科学扩展其概念工具箱，但不一定需要根本性的方法论革新。

如果采取关系主义立场，研究者需要更加关注人机互动的过程和语境。研究的重点不再是 AI“是什么”，而是 AI 在特定关系中“做什么”。这可能需要借鉴科学技术研究（STS）、人机交互研究（HCI）和符号互动论的方法，强调对具体互动过程的细致观察和分析。

我个人倾向于一种务实的立场：根据研究问题的性质选择适当的本体论框架。当研究 AI 对劳动市场的宏观影响时，工具主义立场可能足够。当研究 AI 在特定互动情境中的角色时，功能主义或关系主义立场可能更有解释力。本体论立场不是教条，而是服务于研究目的的分析工具。

## 17.3 二、模拟社会与虚拟样本

### 17.3.1 2.1 AI 驱动的社会模拟

AI 在社会科学中的一个新兴应用是构建“模拟社会”（simulated societies）。研究者使用大语言模型作为模拟人类行动者的基础，让多个 AI“代理”（agents）在虚拟环境中互动，观察涌现出的社会模式和动态。

这种方法并非全新——基于代理的模型（Agent-Based Models, ABM）在社会科学中已有数十年历史。传统的 ABM 使用简单的规则来定义代理的行为，例如“如果邻居中超过 50% 是不同群体，就搬迁”（谢林隔离模型）。这些简单规则可以产生复杂的涌现现象，帮助研究者理解社会动态的微观基础。

大语言模型的引入为 ABM 带来了质的变化。与基于固定规则的代理不同，LLM 驱动的代理能够生成更加丰富和语境敏感的“行为”。它们可以进行对话、表达态度、做出看似合理的决策。一些研究者已经开始使用这种方法来模拟政治讨论、市场行为、组织决策等社会过程。

斯坦福大学的研究团队在 2023 年发表了一项引人注目的研究，他们创建了一个由 25 个 LLM 驱动的代理组成的虚拟小镇。每个代理都有自己的“个性”和“记忆”，它们在虚拟环境中生活、工作、社交。研究者观察到这些代理展现出了一些有趣的社会行为，如自发形成社交网络、传播信息、协调集体活动。

### 17.3.2 2.2 虚拟样本的方法论问题

另一个相关的应用是使用 AI 生成“虚拟样本”或“硅样本”（silicon samples）——让大语言模型模拟人类被试对调查问卷、实验刺激或访谈问题的反应。这种方法的吸引力在于其低成本和高效率：不需要招募真人被试，不需要等待数据收集，只需要设计好提示词就可以快速获得大量“数据”。

一些研究者对此表现出热情。他们指出，LLM 是在海量人类文本上训练的，因此可能“编码”了某些人类态度和行为的统计规律。如果这个假设成立，那么 LLM 的输出可能在某种程度上反映真实人类的反应分布。一些初步研究声称，LLM 在某些调查任务上的表现与真人样本的结果具有相关性。

然而，这种方法面临严重的方法论挑战。

首先是“真实性”问题。LLM 的输出真的反映了人类的态度和行为吗？还是只是反映了训练数据中的文本模式？LLM 被训练来预测“最可能的下一个词”，这与人类形成和表达态度的认知过程有本质区别。LLM 可能会输出它“认为”人类会说的话，而这种输出更多反映的是文本模式而非真实的人类心理。

其次是“代表性”问题。即使 LLM 的输出在某种程度上反映了人类反应，它反映的是哪些人类的反应？LLM 的训练数据并非人类群体的随机样本，而是偏向于互联网上的英语文本，偏向于某些地区、教育水平和社会群体。这种训练数据的偏差会系统性地影响 LLM 的输出，使其无法代表更广泛的人类群体。

第三是“一致性”问题。人类被试的反应受到许多因素的影响——个人经历、当下情绪、问题措辞、调查情境等。LLM 没有这些真实的经历和情境，它的“反应”是基于统计模式的生成，可能会表现出与真人不同的变异模式。一些研究发现，LLM 的输出往往过于一致和“理想化”，缺乏真人反应中的噪音和异质性。

第四是“效度推断”问题。即使 LLM 的输出与真人样本的结果在某些任务上相关，这种相关性能否推广到其他任务？相关性的存在并不意味着底层机制相同。LLM 可能因为完全不同的原因而产生表面上相似

的输出，这使得从模拟结果向真实人类行为的推断变得极其危险。

### 17.3.3 2.3 模拟的认识论地位

面对这些挑战，我们应该如何看待 AI 驱动的社会模拟和虚拟样本？我认为关键在于明确其认识论地位。

模拟不是经验研究的替代品，而是理论探索的工具。模拟可以帮助研究者探索理论假设的含义——如果某些条件成立，会产生什么样的社会动态？模拟可以生成假说，这些假说随后需要通过真正的经验研究来检验。模拟可以帮助研究者理解复杂系统的可能行为空间，而不是预测具体的经验结果。

从这个角度看，AI 驱动的社会模拟与传统的数学模型和计算模拟具有相似的认识论地位。我们不会认为一个经济学模型的“均衡解”证明了“市场的真实行为”，我们也不应该认为一个 LLM 驱动的社会模拟“证明了”人类社会的真实动态。模型和模拟的价值在于提供思维工具和生成假说，而非产出经验结论。

对于虚拟样本，我认为需要更加谨慎。将 LLM 的输出作为人类反应的代理是一种高风险的方法论选择。即使在某些特定任务上观察到了与真人结果的相关性，这种相关性的稳健性和可推广性都高度不确定。在当前阶段，虚拟样本最多只能作为真正经验研究的补充——例如用于预测试调查问题的可理解性，或者快速迭代实验设计——而不能作为替代。

### 17.3.4 2.4 负责任的模拟研究

如果研究者决定使用 AI 驱动的社会模拟，应当遵循哪些原则？

第一是透明性原则。研究者应当详细报告模拟的设置——使用的模型、提示词设计、代理的参数设定、模拟的运行条件。其他研究者应当能够基于这些信息复现模拟，评估结果的稳健性。

第二是明确边界原则。研究者应当清晰地陈述模拟结果的适用范围和局限性。模拟结果是关于“如果 LLM 驱动的代理在这些条件下互动会发生什么”的陈述，而不是关于“真实人类在类似条件下会如何行为”的陈述。任何从模拟向真实世界的推断都需要额外的论证和证据支持。

第三是与经验研究结合原则。模拟结果应当与经验研究相互印证。如果模拟产生了有趣的假说，这些假说应当通过真人被试的研究来检验。如果模拟结果与已有的经验证据一致，这可以增加对模拟的信心，但不能替代独立的经验验证。

第四是反思性原则。研究者应当反思模拟中的假设和简化可能如何影响结果。LLM 驱动的代理真的捕捉到了对研究问题重要的人类行为特征吗？模拟环境中遗漏了哪些真实社会情境的关键因素？这种反思不是为了否定模拟的价值，而是为了更清晰地理解其局限。

## 17.4 三、“行动者”概念的扩展

### 17.4.1 3.1 从人类行动者到异质行动者

AI 的兴起促使我们重新思考“行动者”这个社会科学的核心概念。传统上，行动者几乎等同于人类行动者——具有意识、意向性和反思能力的个体。组织、国家等集体有时也被视为行动者，但这通常被理解为一种隐喻或分析便利，其“行动”最终可以还原为组成它们的人类个体的行动。

然而，当我们观察 AI 在社会中的实际角色时，这种人类中心的行动者概念显得越来越不够用。考虑以下场景：

一个算法决策系统拒绝了某人的贷款申请。在这个场景中，谁是“行动者”？是设计算法的工程师？是部署算法的银行？是做出具体决策的算法本身？还是提供训练数据的历史贷款记录？传统的行动者概念难以捕捉这种分布式的、人机交织的决策过程。

一个 AI 聊天机器人在社交媒体上与用户互动，影响了用户的政治态度。这种影响应该如何归因？AI“说了”某些话，用户“被影响了”，但 AI 没有意图，用户可能没有意识到自己在与 AI 互动。这种互动不符合传统的人际互动模型，但它确实产生了社会后果。

### 17.4.2 3.2 行动能力的分解

一个有帮助的概念策略是将“行动者”分解为多个维度，而不是视其为单一的、不可分割的属性。



第一个维度是“因果效力”(causal efficacy)。一个实体是否能够在物理世界或社会世界中产生因果后果?按这个标准, AI 显然具有因果效力——它的输出确实影响了人们的决策和行为。

第二个维度是“反应性”(responsiveness)。一个实体是否能够感知环境并根据环境做出调整?按这个标准, AI 也具有一定程度的反应性——它能够处理输入并生成语境相关的输出。

第三个维度是“意向性”(intentionality)。一个实体是否具有信念、欲望和目标,并且其行为是由这些心理状态引导的?这是一个争议性更大的维度。AI 是否具有“真正的”意向性,取决于我们如何定义意向性以及是否接受功能主义的解释。

第四个维度是“反思性”(reflexivity)。一个实体是否能够反思自己的行为、评估自己的表现、修正自己的目标?当前的 AI 在这个维度上的能力相当有限,尽管一些研究者正在探索赋予 AI 更多“自我意识”的可能性。

第五个维度是“问责性”(accountability)。一个实体是否能够对其行为负责,是否能够被要求解释和辩护其行为?这既是一个能力问题,也是一个社会建构问题——我们作为社会是否愿意将 AI 视为可问责的实体?

通过这种分解,我们可以更精细地描述 AI 在行动者连续谱上的位置。AI 可能在因果效力和反应性维度上得分较高,在意向性和反思性维度上得分较低,在问责性维度上处于争议之中。这种分解比简单的“是否是行动者”的二元判断更有分析价值。

### 17.4.3 3.3 人机混合行动者

另一个重要的概念发展是“人机混合行动者”(human-machine hybrid agents)的概念。在许多实际情境中,行动并非完全由人类或完全由 AI 完成,而是人类和 AI 共同参与的混合过程。

考虑一个使用 AI 辅助写作的研究者。最终的论文是谁的“作品”?研究者提供了研究问题、数据和核心论点, AI 协助了文字表达和结构组织,研究者又对 AI 的输出进行了修改和整合。这种协作产出的作品难以简单地归属于人类或 AI 中的任何一方。

又如一个使用 AI 驱动推荐算法的内容平台。用户看到什么内容是用户选择、算法推荐和内容创作者决策共同作用的结果。平台的信息环境是这个人机混合系统的涌现产物,而非任何单一行动者的意图。

这种人机混合行动者的概念对传统的责任归属框架提出了挑战。如果行动是人类和 AI 共同完成的,责任应该如何分配?如果 AI 的参与程度难以精确量化,个人责任和系统责任的边界在哪里?

一些学者提出,我们需要发展新的“分布式责任”(distributed responsibility)框架来应对这些挑战。这种框架不是将责任归属于单一行动者,而是考察责任在人机系统各个环节的分布。设计者、部署者、使用者和 AI 本身都可能承担不同方面和程度的责任,具体取决于情境和后果的性质。

### 17.4.4 3.4 对社会理论的启示

行动者概念的扩展对社会理论有什么启示?

首先,它提醒我们社会理论的核心概念往往隐含着特定的本体论假设。当这些假设面临挑战时,我们需要回到概念的基础进行反思。“行动”究竟意味着什么?“社会”是否必然由人类构成?“意义”是否必须有主体作为来源?这些问题在 AI 时代获得了新的紧迫性。

其次,它表明社会理论可能需要发展更加灵活和多元的概念框架。与其坚持单一的行动者定义,不如承认行动能力是多维的、程度性的、语境依赖的。不同的研究问题可能需要不同的概念化方式。

第三,它指向了人机关系作为社会理论新前沿的重要性。人类社会正在越来越深地与 AI 系统交织在一起。理解这种交织——它如何改变权力关系、如何重塑社会互动、如何影响意义生产——可能成为未来社会理论的核心议题之一。

## 17.5 四、研究者的立场与策略

### 17.5.1 4.1 明确研究对象

面对 AI 作为行动者带来的复杂性,研究者首先需要明确自己的研究对象。我建议区分三种不同的研究取向。

第一种取向是研究“人类与 AI 的互动”。这种取向将 AI 视为人类行动的环境因素或互动对象，关注的核心仍然是人类——人类如何感知 AI、如何与 AI 互动、如何被 AI 影响。研究方法可以借鉴传统的人机交互研究和技术社会学。

第二种取向是研究“人机系统的涌现特性”。这种取向关注人类和 AI 共同构成的系统，研究系统层面的模式和动态，而不将其还原为人类或 AI 任何一方的属性。研究方法可以借鉴系统论和复杂性科学。

第三种取向是研究“AI 本身的行为特性”。这种取向将 AI 作为一种新型实体来研究，关注 AI 的“行为”规律、“能力”边界和“偏差”模式。这种研究对于理解 AI 系统如何工作以及预测其社会影响非常重要，但研究者需要谨慎避免将人类心理学的概念不加反思地应用于 AI。

这三种取向并非互斥，同一个研究者可以根据不同的研究问题采取不同的取向。关键是要明确自己在做什么，避免在不同取向之间无意识地滑动。

## 17.5.2 4.2 保持方法论自觉

无论采取哪种研究取向，研究者都需要保持高度的方法论自觉。

当使用 AI 模拟人类行为时，要明确区分模拟结果和经验事实。模拟可以生成假说，但不能验证假说。模拟可以探索可能性空间，但不能断言现实世界的实际状态。任何从模拟向现实的推断都需要额外的论证和经验支持。

当使用 AI 生成的数据时，要仔细评估数据的效度和局限。AI 生成的文本是一种特殊类型的数据，它反映的是模型的训练数据和生成机制，而非直接反映社会现实。研究者需要发展专门的方法来分析这类数据，而不是简单地将其等同于人类生成的文本。

当研究人机互动时，要注意互动的特殊性质。人与 AI 的互动既不同于人际互动，也不同于人与普通技术的互动。AI 的“反应”具有某种类人的特质，这可能影响人类的认知和情感反应。研究方法需要敏感于这种特殊性。

## 17.5.3 4.3 伦理考量

AI 作为行动者的问题还涉及重要的伦理考量。

如果 AI 在社会中发挥着越来越重要的作用，我们如何确保这种作用是有益的、公平的、可控的？这不仅是技术问题，也是社会和政治问题。研究者有责任揭示 AI 系统的运作机制、识别其潜在风险、参与关于 AI 治理的公共讨论。

如果 AI 被用于模拟人类行为，这种模拟的伦理边界在哪里？模拟特定个人是否侵犯隐私或尊严？模拟特定群体是否可能强化刻板印象？这些问题需要研究伦理框架的更新和扩展。

如果研究涉及人类与 AI 的互动，传统的知情同意原则如何适用？当用户与 AI 互动时，他们是否充分理解自己在与什么互动？研究者在设计涉及 AI 的研究时，需要考虑这些新型的伦理挑战。

## 17.5.4 4.4 跨学科对话

AI 作为行动者的问题本质上是跨学科的，需要社会科学、计算机科学、哲学和其他领域的对话与合作。

社会科学家需要理解 AI 系统的技术基础——模型是如何训练的、输出是如何生成的、系统的能力和限制是什么。这种技术理解不需要达到工程师的水平，但需要足够深入，以避免对 AI 能力的过度神话化或过度恐惧。

计算机科学家需要理解社会科学的关切——社会影响、公平性、问责性、意义等问题。技术系统的设计选择往往隐含着社会和伦理假设，跨学科对话可以帮助揭示和反思这些假设。

哲学家可以为行动者、意向性、责任等核心概念的分析提供资源。AI 带来的概念挑战往往与哲学的传统问题相关联，哲学分析可以帮助澄清概念混乱、识别隐含假设、探索可能的理论选择。

## 17.6 结语：在工具与行动者之间

本章探讨了 AI 作为行动者的多重维度。AI 正在从单纯的工具演变为社会系统中更复杂的存在——它影响着人类的决策和互动，它被用来模拟人类行为，它挑战着我们对行动者的传统理解。

这种演变既带来了研究机会，也带来了方法论挑战。AI 驱动的社会模拟和虚拟样本为社会科学研究提供了新的探索工具，但这些工具的认识论地位需要被仔细界定。AI 的广泛部署使人机互动成为重要的研究领域，但这种互动的特殊性质需要被充分认识。行动者概念的扩展开启了新的理论可能性，但也要求我们重新审视社会理论的基本假设。

我的基本立场是务实的多元主义。根据研究问题的性质，AI 有时可以被视为工具，有时可以被视为准行动者，有时则需要被理解为人机混合系统的组成部分。重要的不是确立一个“正确的”本体论立场，而是明确自己在每个研究情境中采取的立场及其含义。

与此同时，我们不应忘记一个基本事实：当前的 AI，无论多么令人印象深刻，仍然是人类创造的技术系统。它们没有自己的目标和利益，它们的“行为”是人类设计和训练的结果。将 AI 视为行动者可能是有用的分析策略，但不应该让我们忽视 AI 背后的人类选择和责任。AI 是由人创造的，为人服务的，也应该由人来治理。

下一章将转向治理层面，探讨 AI 如何改变学术制度本身，以及研究者在这个变革中应该承担的责任。

## 18 第 17 章 Governance Level：制度与治理层

在治理层，问题已经超越“如何使用 AI”，而是“AI 如何改变学术制度”。当 AI 可以大规模生成文本，学术评价体系会发生什么变化？当研究流程被自动化，学术劳动的价值如何被重新定义？

这一层的核心是结构性影响：论文产出可能变得更快，但“学术质量”可能被稀释；评审机制可能更依赖表面表达，忽视真实研究价值。AI 带来的不是简单的效率提升，而是制度逻辑的重构。

研究者需要在治理层承担新的责任：明确 AI 使用边界、推动透明化、参与学术伦理讨论。真正的挑战不是“AI 能不能用”，而是“学术共同体如何定义可信”。

## 19 终章 | AI 时代研究者的新能力结构

AI 让研究更快，这是事实。但更快不等于更深。真正的问题是：在 AI 时代，研究者的不可替代能力是什么？答案不是“会的工具”，而是“能够提出问题、建立证据链、守住方法论边界”。

未来的研究者需要新的能力结构：一是系统化的问题意识；二是对证据的严格要求；三是对 AI 输出的批判性判断。AI 可以帮助你节省时间，但它不会替你承担学术责任。

开源在这个时代变得更重要。它不仅是分享资源，更是对学术可信度的回应。面对 AI 可能带来的“空洞高产”，开源与可复现是一种必要的抵抗：把研究拉回事实、证据与共同体的监督之中。

## 20 附录（可选）

本书后续版本将提供以下配套材料，全部开源更新：

- AI 科研工具箱清单（按任务分类）
- 提示词模板与工作流脚本（可复用）
- 案例复现材料与数据链接（含版本号）
- AI 使用伦理与声明模板（投稿与答辩场景）

附录的目的不是堆工具，而是让方法论落地。读者可以根据自己的研究领域替换工具，但不应跳过验证与记录步骤。

Knuth, Donald E. 1984. “Literate Programming.” *Comput. J.* 27 (2): 97–111. <https://doi.org/10.1093/comjnl/27.2.97>.